影像處理 Image Processing

大學智慧機器人學程 | 高中 AI 機器人課程 | 台灣自編大學教科書

編者：李世淵(機器人叫獸)|助教：李天宇、李宇晴

第 7 章 影像還原

本章學習目標

- 區分影像強化與影像還原的目標差異，寫出影像劣化的數學模型並說明其病態性。
- 說明影像還原與第 5 章空間濾波、第 6 章低通/高通濾波在觀念上的一致性與差異。
- 辨識高斯、椒鹽、均勻、Poisson、週期性等雜訊型態，並以直方圖與平坦區統計量估計雜訊參數。
- 運用排序統計濾波、自適應局部降噪濾波與非局部平均處理不同型態的雜訊。
- 說明逆濾波為何失敗，推導維納濾波與約束最小平方濾波如何加以修正。
- 以維納濾波還原模糊與含雜訊的影像，並以 PSNR 與 SSIM 量化成效。
- 評估影像還原對後續邊緣偵測、特徵擷取與物件偵測的影響。
- 認識反覆式反卷積與 AI 影像修復的原理，並思辨「還原」與「腦補」的界線。

叫獸開講|馬蓋先重生記與哈伯望遠鏡的太空救援

先說一個溫暖的故事。1985 年開播的影集《百戰天龍》(MacGyver)，陪伴了一整個世代的台灣觀眾——那位不用槍、只靠一把瑞士刀和滿腦子物理化學知識就能脫困的馬蓋先，大概是許多工程師最早的偶像。然而，三十多年前的類比訊號母帶畫質模糊、雜訊滿佈，以今天的螢幕觀看幾乎不忍卒睹。近年來，透過 AI 影像修復技術，那段經典的片頭曲被重製成 4K 畫質：雜訊被抹去、邊緣重新銳利、色彩重獲飽和，馬蓋先以前所未有的清晰度重返螢幕。這是「影像還原」最貼近生活的示範。

再說一個驚心動魄的故事。1990 年 4 月，人類史上最昂貴的科學儀器之一——哈伯太空望遠鏡升空。所有人屏息等待它傳回宇宙深處的照片，結果收到的卻是一張張模糊的影像。工程師追查後發現一個令人心碎的錯誤：主鏡的研磨形狀有偏差，產生球面像差，使得點光源超過八成的光線被散射成半徑二至三角秒的光暈。一個微小到以微米計的加工誤差，讓十幾億美元的望遠鏡近乎失明。

修復需要太空人上去動手術，但那是三年後(1993 年 12 月)的事。在那之前的三年，天文學家怎麼辦?他們選擇了另一條路：既然模糊的成因(點擴散函數，PSF)可以被測量與建模，那就用數學把影像「解模糊」回來。維納濾波、Richardson-Lucy 反覆演算法、最大熵法等一系列反卷積技術被大規模投入，竟然真的從模糊資料中救回了大量可用的科學成果。1993 年太空人裝上 COSTAR 校正光學系統與新的 WFPC2 相機後，硬體問題才根本解決——但那三年間，是影像還原技術替人類守住了通往宇宙的窗口。

兩個故事，一今一古，正好對應本章的兩條路線：傳統的數學還原(第 7.5 節的逆濾波、維納濾波與約束最小平方)靠的是「理解劣化的物理過程，再反推回去」;現代的 AI 修復(第 7.8 節)靠的是「從海量影像中學會世界長什麼樣子，然後補上」。前者誠實但受限，後者驚豔但危險——因為它補出來的細節，可能從來不存在。

思考題：如果法庭上的監視器畫面經過 AI 超解析度處理，把模糊的車牌「還原」成清晰的號碼，這個證據可以採信嗎?請從本章兩條路線的差異思考。

7.1 影像還原的定位、模型與病態性

7.1.1 還原與強化的差別

第 5、6 章談的是影像強化(Enhancement)：目標是讓影像「看起來更好」，判準相當主觀——把夜景調亮、把邊緣變銳利，好不好看你說了算。本章的影像還原(Restoration)則是客觀的逆問題：先建立劣化的數學模型，再設法反推出最接近原始

影像的估計。它問的不是「怎樣比較好看」，而是「原本長什麼樣子」，因此可以用第 3 章介紹的 PSNR、SSIM 等指標客觀驗收。

這個差別在工程實務上非常關鍵。舉例來說：同樣是讓模糊的影像變清楚，第 5 章的 Unsharp Masking 只是「把邊緣兩側的對比拉大」，製造出銳利的視覺印象，原本被模糊掉的細節並沒有回來;而本章的反卷積則是「依據模糊的數學模型，把被抹平的高頻成分算回去」。前者是化妝，後者是手術。也因此，還原方法需要更多的先驗知識(退化函數、雜訊統計量)，而且在資訊確實已經完全消失的情況下，它也無能為力——這是所有還原技術的物理上限。



圖 7-1　強化讓影像看起來清楚，還原讓影像真的接近原貌

比較項目	影像強化(第 5、6 章)	影像還原(本章)
目標	看起來更好、更適合後續處理	逼近原始未劣化的影像
判準	主觀(人眼、下游任務表現)	客觀(MSE、PSNR、SSIM)
需要的知識	幾乎不需要先驗知識	退化函數 h、雜訊統計特性
代表方法	直方圖等化、Gamma、平滑與銳化	維納濾波、約束最小平方、反覆式反卷積

數學性質	正問題(直接運算)	逆問題(常為病態問題)

表 7-1 影像強化與影像還原的比較

7.1.2 劣化模型

標準的劣化模型是：g(x, y) = h(x, y) * f(x, y) + n(x, y)，其中 f 是原始影像，h 是退化函數(以卷積作用，例如失焦模糊、運動模糊、光學系統的點擴散函數 PSF),n 是加性雜訊，g 是我們實際拿到的影像。依第 6 章的卷積定理，在頻率域可寫成 G = H·F + N——空間域的卷積變成乘法，還原問題於是變成「已知 G 與 H，如何解出 F」的代數問題。這正是頻率域方法在本章大放異彩的原因，也再次印證第 6 章的核心訊息：換一個域，難題就換一副面孔。

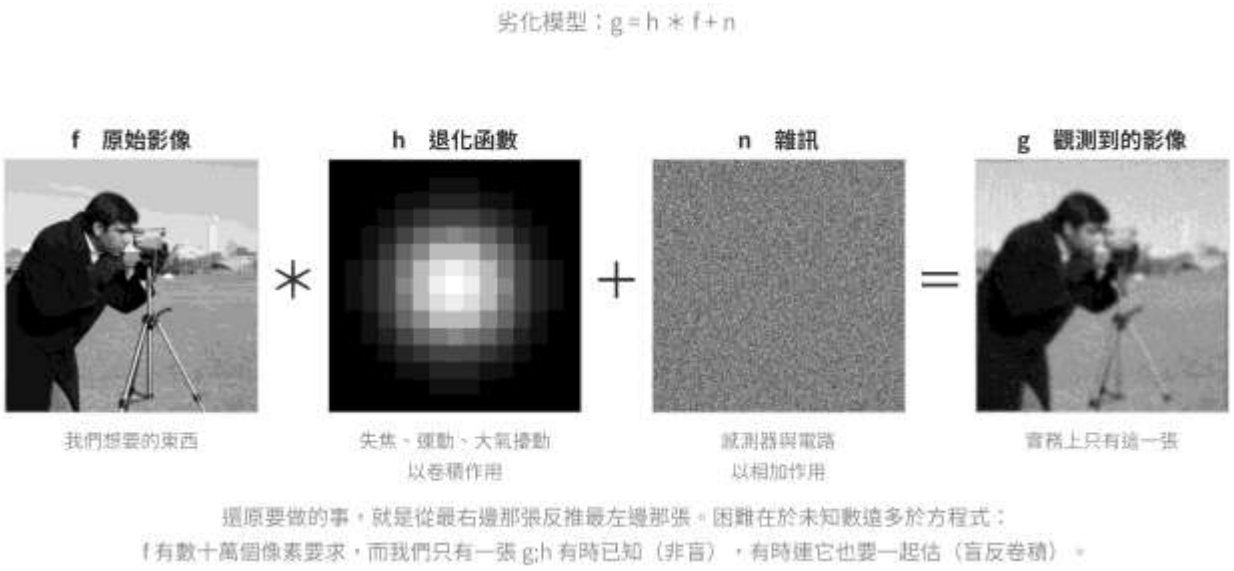


*圖 7-2　劣化模型 g = h * f + n 的四個組成*

請留意這個模型隱含的三個假設，以及它們在真實系統中可能失效的情形：第一，退化是線性且位置不變的(整張影像用同一個 h)。實務上鏡頭邊緣的模糊往往比中心嚴重，哈伯望遠鏡的 PSF 甚至隨時間與位置變動，這時就需要分區塊處理或更複雜的模型。第二，雜訊是加性的且與訊號獨立。這對高斯雜訊成立，但對 Poisson 雜訊(第 7.2 節)並不成立，因為它的強度隨訊號變化。第三，雜訊是零均值的。若感測器有直流偏移(dark current)，必須先做暗電流校正再進入還原流程。

依 h 是否已知，還原問題分為兩類難度：若 h 已知(例如哈伯望遠鏡的 PSF 可由觀測標準星測得、運動模糊的方向與長度可由拍攝參數推算)，稱為非盲反卷積(Non-blind Deconvolution);若 h 未知，必須同時估計 h 與 f，稱為盲反卷積(Blind Deconvolution)。後者困難得多——因為「模糊的影像 = 清楚的影像卷積大模糊核」與「稍微模糊的影像卷積小模糊核」可以得到完全相同的觀測結果，解不唯一，必須靠額外的先驗假設(例如自然影像的梯度分布特性)才能收斂到合理解。

7.1.3 為什麼是病態問題

數學上，一個問題被稱為適定問題(Well-posed)，必須滿足三個條件：解存在、解唯一、解對資料連續依賴(輸入的微小擾動只造成輸出的微小變化)。影像還原問題最常違反的是第三條：退化函數 h 是低通性質的，它把高頻成分壓到接近零;還原時要把這些成分放大回來，等於乘上一個極大的倍數，而觀測資料中不可避免的微小雜訊也會被同等放大。輸入端萬分之一的擾動，可能在輸出端變成鋪天蓋地的雪花——這就是病態(Ill-posed)。

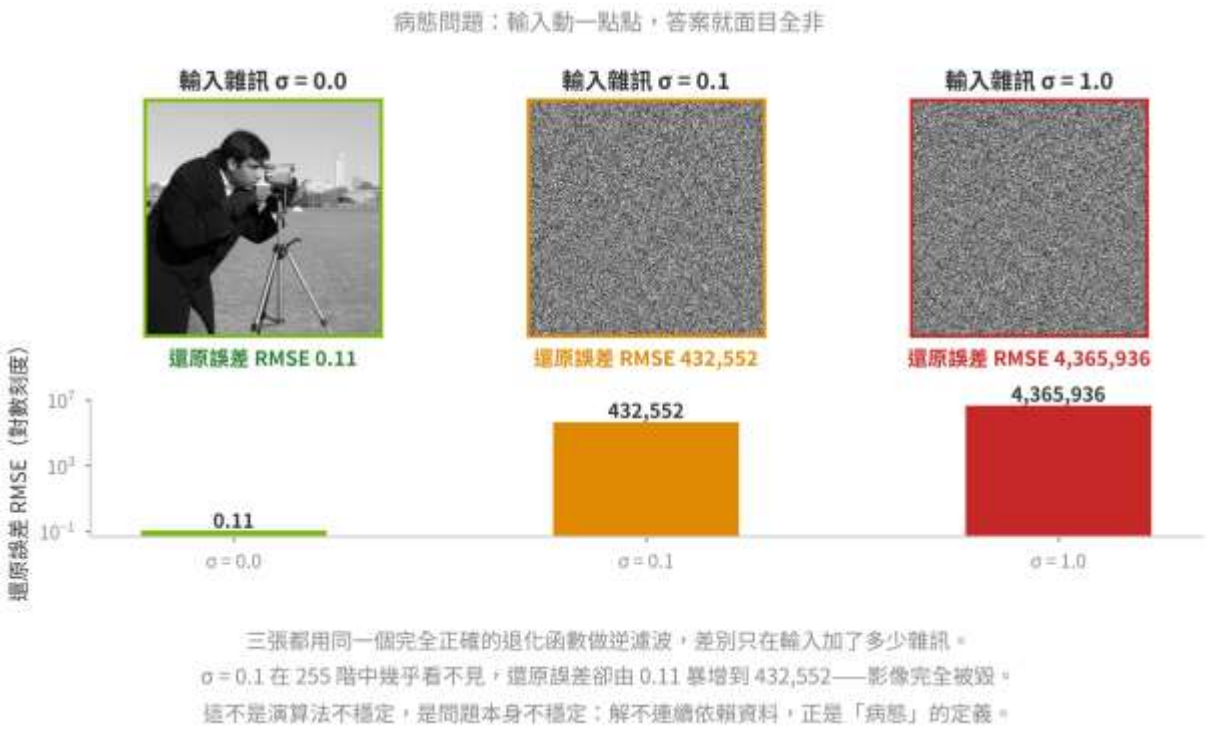


圖 7-3　病態問題：輸入動一點點，答案就面目全非

解決病態問題的通用策略叫正則化(Regularization)：在「忠實還原資料」之外，額外加上對解的約束，例如「影像應該是平滑的」、「影像的梯度應該是稀疏的」。維納濾波中的雜訊訊號比項、約束最小平方法中的平滑度項、以及深度學習模型從資料學到的先驗，本質上都是正則化的不同形式。理解這一點，你就抓住了整章的骨架：所有還原方法的差別，只在於「用什麼方式告訴演算法：合理的影像應該長什麼樣子」。

7.1.4 本章在全書中的位置

影像還原是一個承先啟後的樞紐章節，它幾乎與本書每一篇都有連結，建議讀者在閱讀本章時隨時回顧與前瞻：

- 與第 3 章(數位影像基礎)：還原成效的驗收工具 MSE、PSNR、SSIM 來自第 3 章;而 RAW 檔保留的高位元深度線性資料，是還原演算法最理想的輸入——8 位元 JPEG 已經過壓縮與 Gamma 編碼，細節與線性關係都已受損。
- 與第 5 章(空間域強化)：中值、高斯、雙邊濾波在本章重新登場，但角色從「讓影像好看」變成「依雜訊模型抑制雜訊」;而夜景模式的多張平均，正是本章「以增加觀測次數對抗隨機雜訊」的實例。
- 與第 6 章(頻率域處理)：劣化模型在頻率域是乘法，還原則是除法;退化函數是低通濾波器，還原則相當於受控的高通增強;週期性雜訊的移除直接沿用第 6 章的陷波濾波。7.4 節會完整展開這條主線。
- 與第 9 章(影像分割)：雜訊會讓 Canny 產生大量假邊緣，模糊則會讓邊緣定位偏移。還原品質直接決定分割品質——7.7 節有量化實驗。
- 與第 13 章(特徵擷取):Harris、SIFT、ORB 都依賴局部灰階變化。模糊會抹平角點的響應值、雜訊會製造大量假特徵點，兩者都使匹配率下降。

- 與第 15、16 章(深度學習與 YOLO)：訓練資料若乾淨、測試場景卻模糊含噪，模型準確率會顯著下滑。還原可作為推論前的前處理，或反過來——把劣化當成資料增強來訓練更強健的模型。
- 與第 17 章(邊緣部署)：還原演算法的運算成本必須納入即時系統的預算。維納濾波需要兩次 FFT,Richardson-Lucy 需要數十次反覆，在 Jetson 上是否跑得動?這是工程決策。

7.1.5 推導：病態到什麼程度，可以用一個數字衡量

7.1.3 節說還原是病態問題，但「病態」聽起來像個形容詞。其實它有一個精確的度量，叫做條件數（condition number），而且在我們的情形下它算起來特別簡單。

先把問題寫清楚。在頻率域，劣化是逐頻率的乘法：$G(u, v) = H(u, v) \cdot F(u, v) + N(u, v)$。也就是說，這個看似龐大的問題其實被拆成了數十萬個互不相干的小問題，每個頻率各自解一個一元一次方程式。對單一頻率而言，解是 $F = (G - N) / H$，而我們不知道 N，只能算 G / H。於是誤差 $= N / H$：輸入端的誤差 N 被放大了 $1/|H|$ 倍。

條件數定義為「最壞情況下的放大倍率除以最好情況下的放大倍率」，在這裡就是 $|H|$ 的最大值除以最小值。以本章使用的高斯失焦為例，$|H|$ 的最大值是 1（直流分量，因為 PSF 的總和為 1），最小值在高頻處可以小到 1e-10 以下，條件數因此達到 1e10 的量級。這個數字的意思很具體：輸入資料中相對大小為 1e-16 的擾動（雙精度浮點數的機器精度），在輸出端可以被放大到 1e-6 的相對誤差;而影像頻譜的數值本身就有上萬的量級，乘起來就是圖 7-15 中那個「一個雜訊都沒加、結果卻跑到正負一千七」的現象。

這個推導帶出三個結論。第一，病態與否完全由 H 決定，與你用什麼演算法無關——換一台精度更高的電腦只是把災難往後推，不會消除它。第二，既然放大倍率是 $1/|H|$，那麼補救的方向就很明確：不要在 $|H|$ 很小的地方做除法。半徑受限逆濾波（7.5.1 節）用的是「乾脆不除」，維納濾波（7.5.2 節）用的是「在分母加一個常數

讓它不會太小」，兩者都是同一個想法的不同實作。第三，條件數也告訴你哪些模糊比較好救：|H| 的最小值愈大（在你關心的頻帶內），條件數愈小，問題愈良性。這是 7.4.1 節「H 的零點就是資訊死亡」的量化版本。

7.2 雜訊模型、辨識與參數估計

7.2.1 常見雜訊型態

1. 高斯雜訊(Gaussian)：機率密度為常態分布，由平均值與標準差兩個參數決定。來源包括感測器熱雜訊、電子電路雜訊、放大器雜訊。它是最常見也最常被假設的雜訊模型，一方面因為它確實普遍，另一方面因為中央極限定理——大量獨立小擾動的總和趨近常態分布。直方圖呈鐘形。

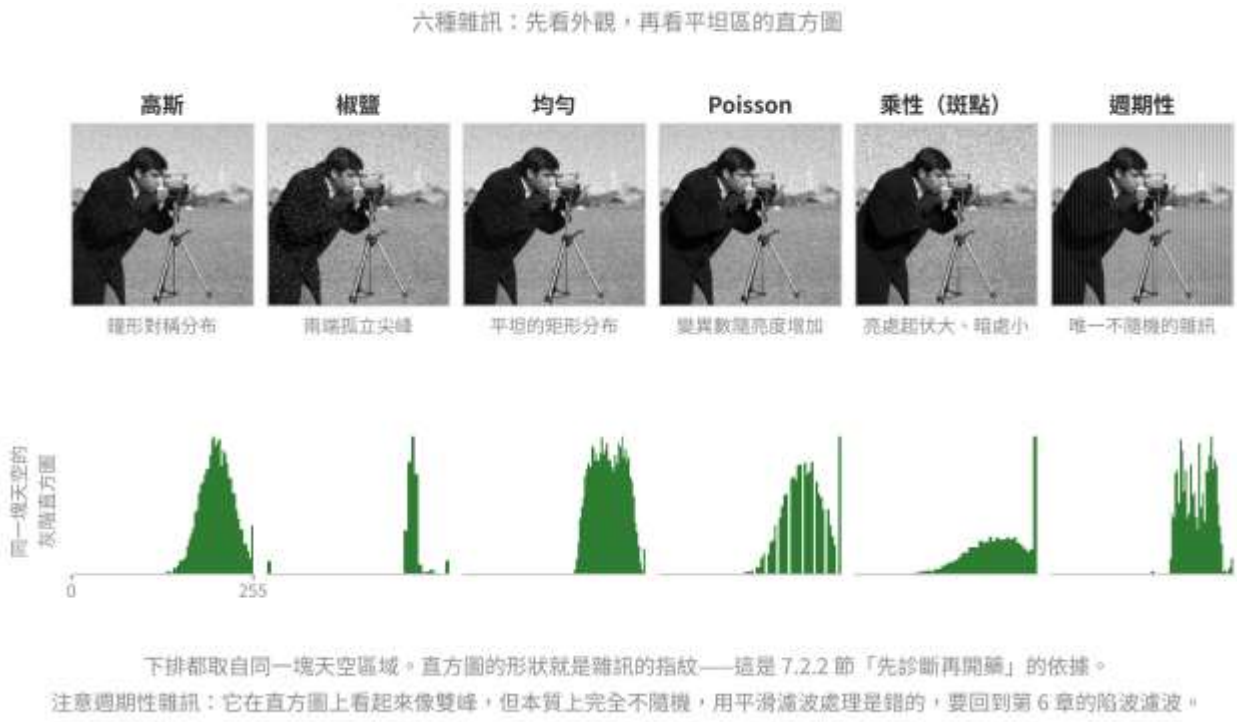


圖 7-4　六種雜訊的外觀與其平坦區直方圖

2. 椒鹽雜訊(Salt-and-Pepper)：又稱脈衝雜訊，像素以某機率隨機變成全黑(0，胡椒)或全白(255，鹽)。來源是訊號傳輸位元錯誤、類比數位轉換失誤、感測器壞點。直方圖在兩端出現孤立尖峰，中間分布不受影響——這是它與高斯雜訊最容易區分的特徵。

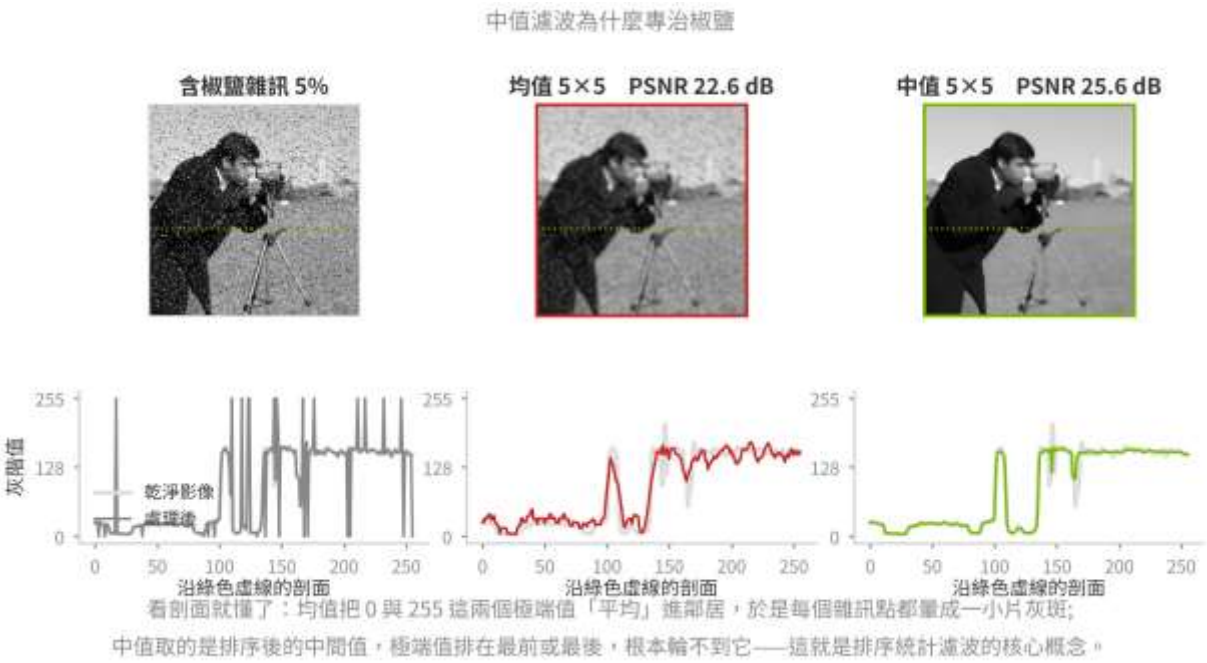


圖 7-9　中值濾波為什麼專治椒鹽：看剖面就懂

3. 均勻雜訊(Uniform)：在某區間內等機率分布。自然界較少見，但量化誤差(第 3 章)的統計特性接近均勻分布，因此在分析位元深度不足造成的失真時會用到。



圖 7-10　自適應濾波在每個位置用了多少力

4. Poisson 雜訊(散粒雜訊，Shot Noise)：源自光子到達感測器的隨機性，其變異數等於平均值——換言之，強度與訊號本身相關：亮處雜訊的絕對值大、暗

處小，但暗處的「相對雜訊」(訊噪比)反而更差。這正是第 5 章夜景模式要對付的主角，也是低光攝影、醫學影像(X 光光子計數)、天文攝影的主要雜訊來源。

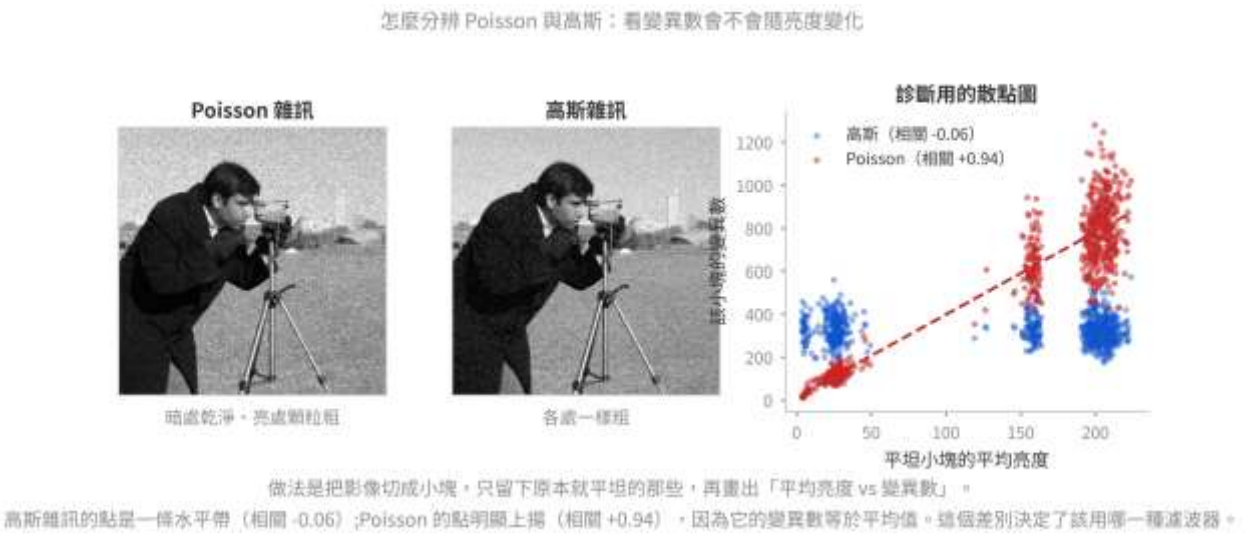


圖 7-5　以變異數是否隨亮度變化分辨 Poisson 與高斯

5. 乘性雜訊與斑點雜訊(Speckle)：雜訊與訊號相乘而非相加，常見於超音波影像、合成孔徑雷達(SAR)。處理策略通常是先取對數把乘法變成加法，再套用加性雜訊的方法，最後取指數還原。



圖 7-11　非局部平均：不問遠近，只問像不像

6. 週期性雜訊(Periodic)：來自電源干擾、機械振動、掃描機構的規律誤差。它是唯一「不隨機」的雜訊，因此不該用平滑濾波處理——正確做法是回到第 6 章的頻率域，以陷波濾波精準移除，詳見 7.4.3 節。

7.2.2 雜訊辨識與參數估計

還原工作的第一步永遠是診斷。實務技巧是：找一塊本該平坦均勻的區域(例如純色背景、牆面、天空、工件的平整表面)，把該區域的像素值取出來分析。因為原始訊號在該區近乎常數，所觀察到的變異幾乎全部來自雜訊。

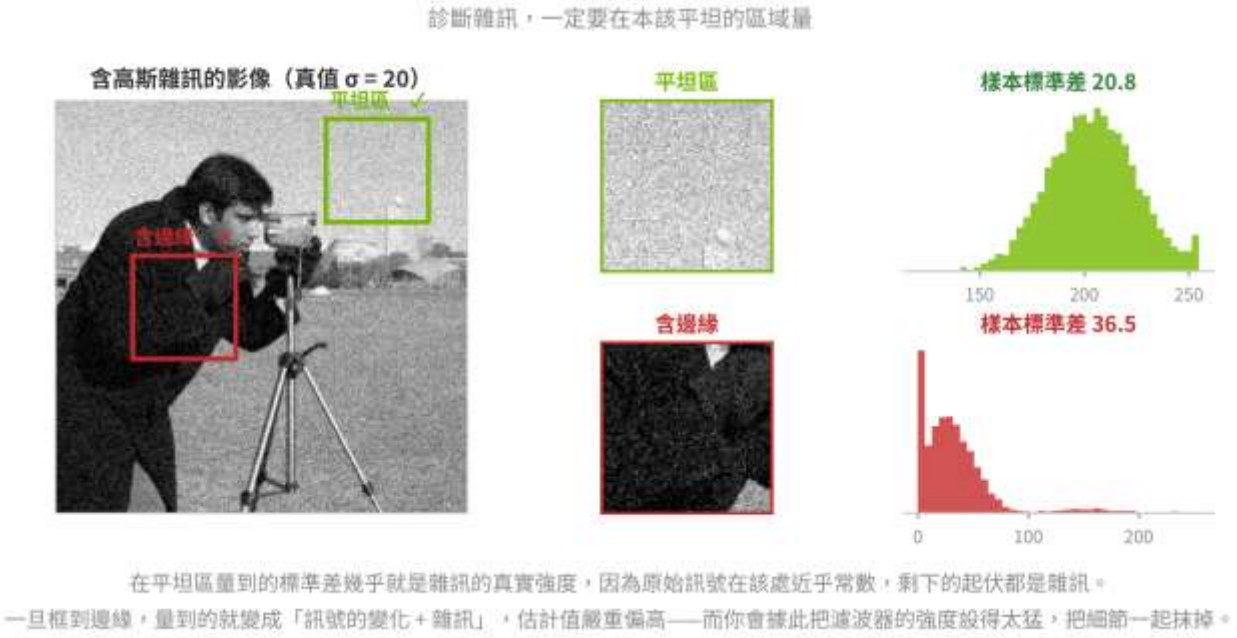


圖 7-6　診斷雜訊一定要在本該平坦的區域量

依直方圖形狀判讀：鐘形對稱分布指向高斯雜訊;兩端出現孤立尖峰、中央分布正常指向椒鹽雜訊;平坦的矩形分布指向均勻雜訊;若變異數隨區域平均亮度成正比增加(需比較亮區與暗區兩塊平坦區)，則指向 Poisson 雜訊。判斷正確，才能選對濾波器——用中值濾波去對付高斯雜訊，或用均值濾波去對付椒鹽雜訊，都是事倍功半的常見錯誤。

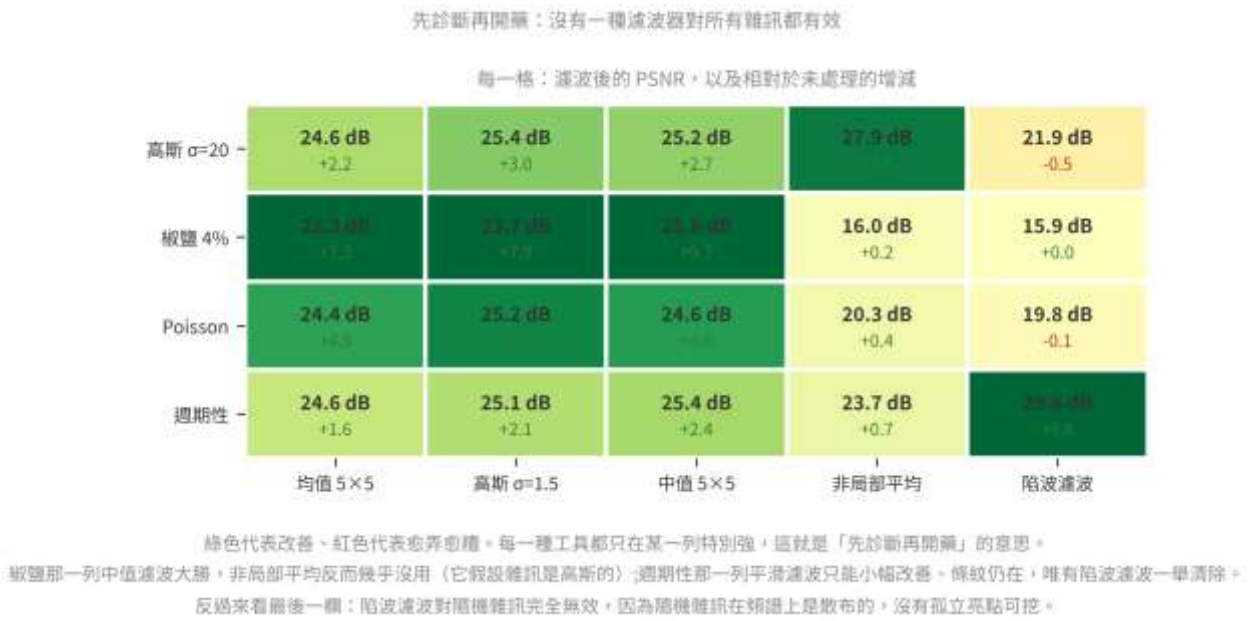


圖 7-8　四種雜訊與五種濾波器的配對矩陣

參數估計則更進一步：高斯雜訊的標準差可直接由平坦區的樣本標準差估得，這個數值是設定維納濾波 K 值、非局部平均 h 參數的重要依據。另一個不需要人工選區的實用技巧，是利用高通濾波的殘差來估計雜訊：對影像做拉普拉斯運算，由於自然影像的高頻能量遠小於雜訊，殘差的統計量可作為雜訊強度的粗估。

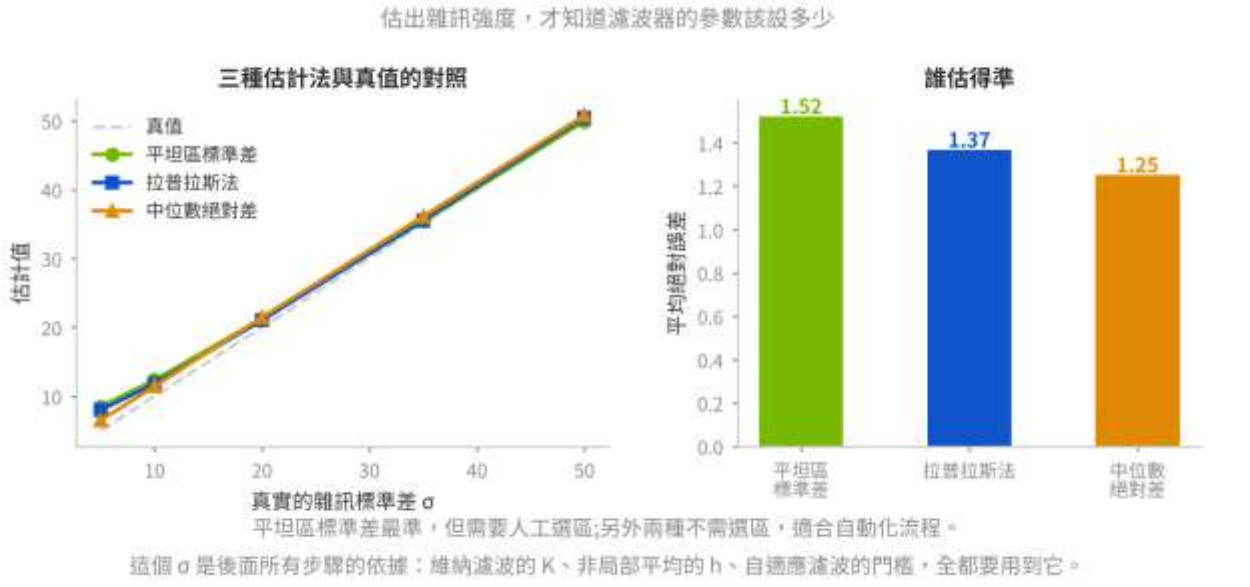


圖 7-7　三種雜訊強度估計法與真值的對照

程式 7-1 產生雜訊影像與估計雜訊參數

```
import cv2, numpy as np

img = cv2.imread("clean.jpg", 0).astype(np.float32)
```

```
# --- 加入高斯雜訊 ---
sigma = 20
gauss = np.random.normal(0, sigma, img.shape)
noisy_g = np.clip(img + gauss, 0, 255).astype(np.uint8)

# --- 加入椒鹽雜訊(各 2%) ---
noisy_sp = img.copy().astype(np.uint8)
p = 0.02
rnd = np.random.rand(*img.shape)
noisy_sp[rnd < p] = 0            # 胡椒(黑)
noisy_sp[rnd > 1 - p] = 255      # 鹽(白)

# --- 加入 Poisson 雜訊(強度隨訊號變化) ---
noisy_po = np.random.poisson(img).clip(0, 255).astype(np.uint8)

# --- 雜訊參數估計 ---
# 方法一:取平坦 ROI 直接算標準差
roi = noisy_g[10:60, 10:60].astype(np.float32)   # 選一塊平坦背景
print("ROI 估計 sigma:", roi.std())

# 方法二:以拉普拉斯殘差估計(免選區)
lap = cv2.Laplacian(noisy_g.astype(np.float32), cv2.CV_32F)
sigma_est = np.sqrt(np.pi / 2) * np.abs(lap).mean() / 6
print("拉普拉斯法估計 sigma:", sigma_est)
```

7.3 空間域去雜訊：從排序統計到非局部平均

當劣化只有雜訊、沒有模糊(即 h 為單位脈衝)時，問題退化為純粹的去雜訊，在空間域處理往往最直接有效。第 5 章介紹的均值、高斯、中值濾波在此重新登場，但這次我們關心的不是「好不好看」，而是「哪一種在對應的雜訊模型下，統計上最接近原始值」。

7.3.1 均值濾波家族

算術平均是高斯雜訊的最佳線性估計：若鄰域內的原始訊號近乎常數，平均 m 個獨立同分布的雜訊樣本，雜訊標準差降為原來的 m 的平方根分之一。這正是第 5 章夜景模式「連拍平均」的數學根據，差別只在於：夜景模式平均的是「不同時間的同一個像素」(訊號完全相同，理想)，而空間平均的是「同一時間的不同像素」(訊號未必相同，因此會模糊邊緣)。這個對照值得學生細細體會——它說明了為什麼多影格去雜訊優於單一影格去雜訊。

幾何平均能在去雜訊的同時比算術平均保留更多細節;諧波平均對鹽雜訊(白點)與高斯雜訊有效，但無法處理胡椒雜訊;反諧波平均則以階數 Q 控制：Q 為正時消除胡椒雜訊，Q 為負時消除鹽雜訊，Q 為零時退化為算術平均——但用錯正負號會使結果更糟，實務上必須先完成 7.2 節的診斷。

7.3.2 排序統計濾波家族

這一族不做算術，而是把鄰域內的像素排序後挑選特定名次的值：中值濾波取中位數，對椒鹽雜訊近乎完美，因為極端值排在最前或最後，永遠不會被選中;最大值濾波取最大值，適合去除胡椒雜訊(黑點)，但會讓亮區膨脹;最小值濾波取最小值，適合去除鹽雜訊(白點);中點濾波取最大與最小的平均，對高斯與均勻雜訊表現不錯;alpha 修剪均值濾波先刪去最大與最小的若干個值再平均，能同時應付混合了高斯與脈衝的雜訊，是實務上很實用的折衷。

這裡也埋著一個與第 10 章的伏筆：最大值與最小值濾波，其實就是型態學的膨脹(Dilation)與侵蝕(Erosion)運算。同一個運算，在本章是「去雜訊工具」，在第 10 章是「形狀操作工具」——影像處理中許多概念都有這種一體多面的性格。

7.3.3 自適應濾波：讓濾波器懂得看場合

固定核濾波的根本缺陷是「一視同仁」：它在平坦區與邊緣區施加同樣強度的平滑，結果不是雜訊沒去乾淨，就是細節被抹掉。自適應濾波的核心思想是：先看看局部的統計特性，再決定要不要動手、動多重的手。

7. 自適應局部降噪濾波器：比較「全域雜訊變異數」與「局部變異數」。若局部變異數接近雜訊變異數，代表這裡是平坦區，雜訊佔主導，應大幅平滑;若局部變異數遠大於雜訊變異數，代表這裡有邊緣或紋理，應盡量保留原值。它的行為可以理解成：平坦處當均值濾波用，邊緣處幾乎不作用。
8. 自適應中值濾波：固定核中值濾波在雜訊密度高時會失效(鄰域內超過一半都是雜訊，中位數本身就是雜訊)，且會抹平細節。自適應版本分兩階段：第一階段

判斷「中位數本身是不是雜訊(等於 0 或 255)」，若是則擴大視窗重試，直到找到有效的中位數或達到視窗上限;第二階段判斷「中心像素是不是雜訊」，若不是就原值保留、完全不動。如此一來，乾淨的像素受到完整保護，只有雜訊點被替換，細節保留能力遠優於固定中值濾波，在雜訊密度達 20% 以上時差距尤其懸殊。

7.3.4 非局部平均：跳脫鄰近的假設

以上所有方法都建立在同一個假設上：相鄰的像素值應該相似。非局部平均(Non-Local Means,NLM)徹底顛覆了這個假設，改為在整張影像中尋找「周圍紋理相似的區塊」來加權平均——不管它離得多遠。它利用的是自然影像的自相似性：磚牆上的每一塊磚、毛衣上的每一道織紋、草地上的每一叢草，在影像各處反覆出現。

具體做法：對每個待處理像素，取一個小的比對視窗(template window，例如 7×7)，在一個較大的搜尋範圍(search window，例如 21×21)內尋找相似的視窗，依相似度給權重再加權平均。因為參與平均的是「內容相同」的像素而非「位置相鄰」的像素，邊緣與紋理得以完整保留，去雜訊能力顯著優於傳統濾波，是深度學習出現前的最強方法之一。代價是運算量大——這也是它在即時系統中較少使用、卻在離線修復(如老照片、醫學影像)中大放異彩的原因。

程式 7-2 五種去雜訊方法的客觀比較

```
import cv2, numpy as np

clean = cv2.imread("clean.jpg", 0)
noisy = cv2.imread("noisy_gaussian.png", 0)

# --- 傳統濾波 ---
mean_f  = cv2.blur(noisy, (5, 5))
gauss_f = cv2.GaussianBlur(noisy, (5, 5), 1.5)
med_f   = cv2.medianBlur(noisy, 5)
bil_f   = cv2.bilateralFilter(noisy, 9, 75, 75)

# --- 非局部平均(h 應依估得的雜訊 sigma 設定) ---
nlm = cv2.fastNlMeansDenoising(noisy, None, h=20,
                               templateWindowSize=7,
                               searchWindowSize=21)
```

```
# --- 客觀比較(第 3 章工具) ---
for name, out in [("原始含噪", noisy), ("均值", mean_f),
                  ("高斯", gauss_f), ("中值", med_f),
                  ("雙邊", bil_f), ("NLM", nlm)]:
    print(f"{name:8s} PSNR = {cv2.PSNR(clean, out):.2f} dB")
```

7.4 頻率域觀點：還原與濾波的血緣關係

這一節是本章與第 6 章的接榫，也是理解所有反卷積方法的鑰匙。請先記住一句話：模糊就是低通濾波，還原就是受控的高通增強。

7.4.1 退化函數是低通濾波器

回想第 6 章：影像的高頻成分對應邊緣與細節，低頻對應平坦區域與整體亮度。任何形式的模糊——失焦、運動、大氣擾動、鏡頭像差——在頻率域上做的事都一樣：把高頻成分的振幅壓低。以高斯模糊為例，它的轉移函數 H 本身也是高斯形狀，中心(低頻)為 1，愈往外(高頻)愈趨近於零。運動模糊的 H 則更兇殘：它是一個 sinc 函數，在某些特定頻率上直接等於零——那些頻率的資訊被完全抹除，再高明的演算法也救不回來。

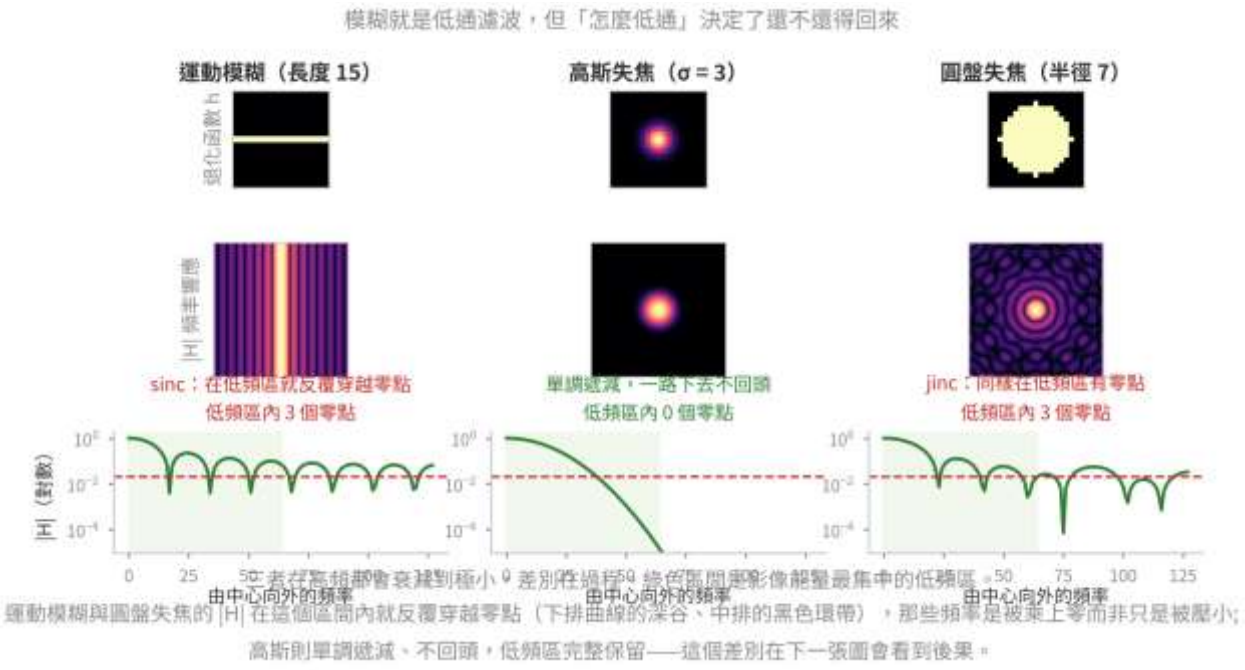


圖 7-12　三種退化函數的頻率響應與它們的零點

這解釋了一個常令初學者困惑的現象：為什麼有些模糊影像還原後很漂亮，有些

卻無論如何都救不回來?答案就在 H 的零點：資訊被乘以零的地方，是真正的資訊死亡，不是演算法不夠好。

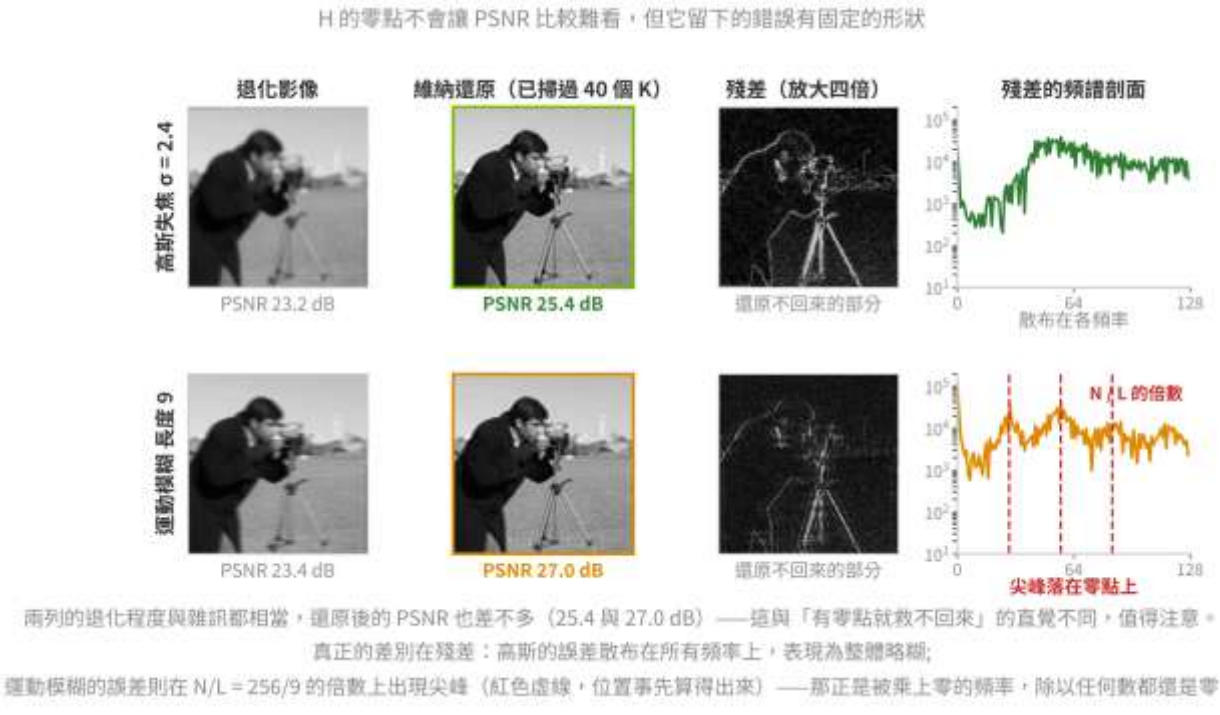


圖 7-13　H 的零點留下的殘差有固定的形狀

7.4.2 還原是受控的高通增強

既然模糊是把高頻乘上一個小數，還原自然就是把它除回來——也就是對高頻施加巨大的增益。這在概念上與第 6 章的高通濾波、第 5 章的 High-Boost 銳化是同一件事：三者都在提升高頻。差別在於：

- 第 5 章的 Unsharp Masking：增益由使用者主觀設定的 k 決定，與造成模糊的物理過程無關。
- 第 6 章的高頻強調濾波：增益由濾波器形狀決定，同樣不管實際的退化函數是什麼。
- 本章的反卷積：增益由退化函數 H 精確決定——H 在哪個頻率壓得多，就在哪個頻率補得多。這是「量身訂做」的高通增強。

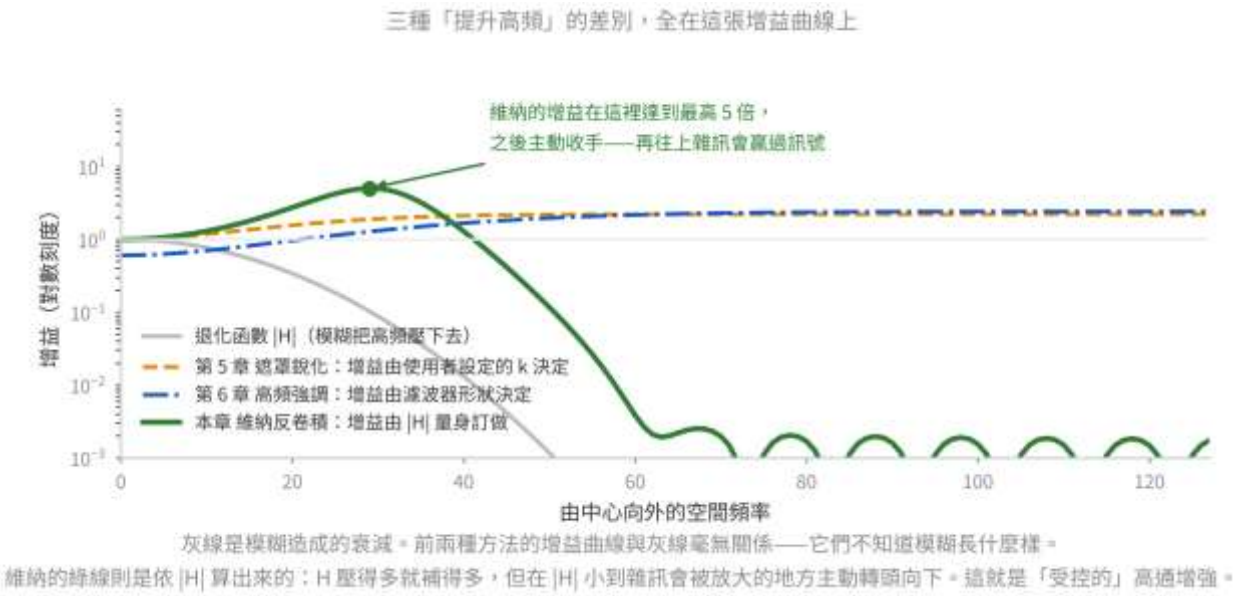


圖 7-14　三種高頻增強的增益曲線對照

而三者共享同一個宿命：雜訊主要分布在高頻，因此任何提升高頻的動作，都必然同時放大雜訊。這是影像處理中最根本的矛盾之一——銳利與乾淨不可兼得。第 5 章用「先去雜訊再銳化」的順序來緩解，第 6 章用平滑的濾波器形狀避免振鈴，而本章的維納濾波與約束最小平方，則是把這個矛盾寫成數學式，直接求出最佳的折衷點。

7.4.3 週期性雜訊：直接沿用第 6 章

週期性雜訊是本章唯一「不需要動用反卷積」的情況。因為它在頻率域上表現為少數幾個孤立亮點，只要以第 6 章的陷波濾波(記得處理共軛對稱點)把那幾點壓下，反轉換即可乾淨移除，且細節毫髮無傷。反之，若誤用空間域的平滑濾波去對付它，必然是全圖細節陪葬。這個例子最能說明「選對域比選對演算法更重要」。

程式 7-3 觀察退化函數的頻率響應

```
import cv2, numpy as np

# 觀察三種退化函數在頻率域的樣貌(理解還原難度)
N = 256

# 高斯模糊 PSF
k = cv2.getGaussianKernel(15, 3); psf_gauss = k @ k.T

# 水平運動模糊 PSF(長度 15)
psf_motion = np.zeros((15, 15), np.float32)
psf_motion[7, :] = 1.0 / 15
```

```
for name, psf in [("gauss", psf_gauss), ("motion", psf_motion)]:
    pad = np.zeros((N, N), np.float32)
    pad[:psf.shape[0], :psf.shape[1]] = psf
    H = np.fft.fftshift(np.fft.fft2(pad))
    mag = np.abs(H)
    print(f"{name}: |H| 最小值 = {mag.min():.6f}")
    # 運動模糊的最小值接近 0 → 該頻率資訊完全喪失,無法還原
    spec = 20 * np.log(mag + 1e-8)
    cv2.imwrite(f"H_{name}.png",
        cv2.normalize(spec, None, 0, 255,
                      cv2.NORM_MINMAX).astype(np.uint8))
```

7.5 反卷積：逆濾波、維納濾波與約束最小平方

7.5.1 逆濾波為何失敗

既然頻率域中 G = H·F + N，最直覺的解法就是兩邊除以 H:F̂ = G / H。若完全沒有雜訊(N = 0)，這個逆濾波確實能完美還原。但真實世界中 N 從不為零，展開後得到：

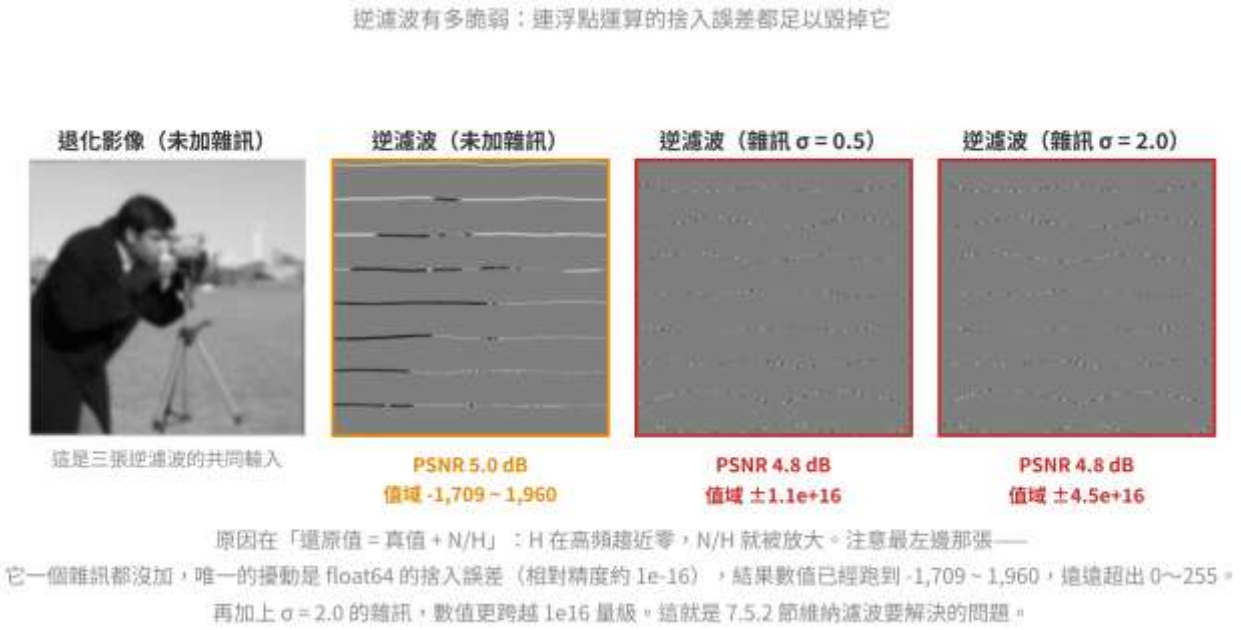


圖 7-15　逆濾波有多脆弱：連捨入誤差都足以毀掉它

$$\hat{F}(u,v) = F(u,v) + N(u,v) / H(u,v)$$

問題就出在第二項。承 7.4.1 節，退化函數 H 在高頻通常趨近於零，當 H 很小時，N/H 會被放大到天文數字，雜訊完全淹沒訊號;若 H 恰好等於零，更是直接除以零。這正是 7.1.3 節所說病態性的具體表現：除法在數學上合法，在工程上災難。

有一個簡單的補救叫半徑受限逆濾波：既然災難發生在高頻，那就只在以頻譜中心為圓心、半徑 D0 之內執行除法，半徑之外一律不動(或設為零)。這相當於「逆濾波 + 低通濾波」的組合，能得到堪用的結果，但 D0 的選擇完全靠試誤，而且截斷會帶來第 6 章的振鈴效應。這個粗糙的做法提示了正確方向：我們需要一個「隨頻率自動調整還原力道」的機制——那就是維納濾波。

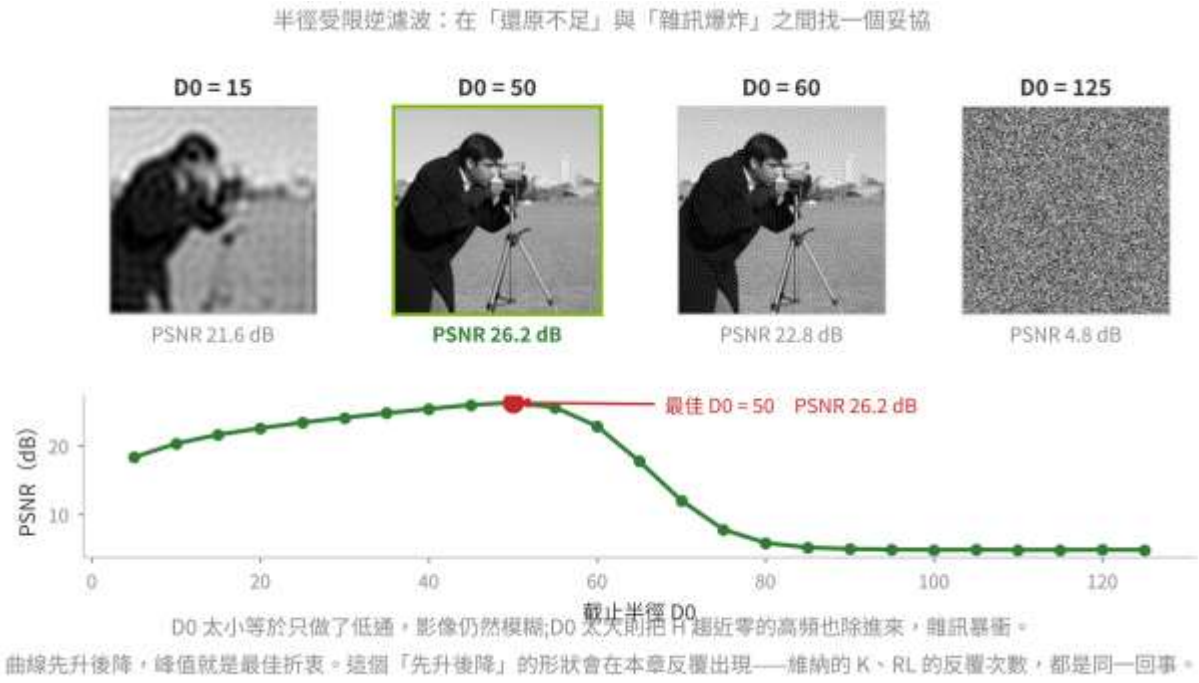


圖 7-16　半徑受限逆濾波的 D0 掃描

7.5.2 維納濾波

維納濾波(Wiener Filter)由 Norbert Wiener 提出，以最小均方誤差為準則，在「還原銳利度」與「抑制雜訊放大」之間取得最佳平衡。其轉移函數為：

$$\hat{F}(u,v) = \left[H^*(u,v) / \left(|H(u,v)|^2 + S_n(u,v)/S_f(u,v) \right) \right] \cdot G(u,v)$$

其中 H* 是 H 的共軛複數，Sn 與 Sf 分別是雜訊與原始影像的功率譜。關鍵在分母多出來的 Sn/Sf 項(常以常數 K 近似，即雜訊對訊號的功率比)：當某頻率的訊號夠強(Sf 大、K 相對小)時，該項趨近 0，公式退化為逆濾波，盡力還原;當訊號微弱而雜訊相對強時，該項變大，壓抑該頻率的還原力道，避免雜訊爆炸。一句話總結：維納濾波是「知道何時該放棄」的逆濾波。

把它與 7.4.2 節對照更能看出巧妙之處：維納濾波在低頻(訊噪比高)做接近完全的高通增強，在高頻(訊噪比低)自動收手，等於內建了一個「依訊噪比自動調整的低通保護」。這也解釋了為什麼維納濾波的結果通常比原圖銳利、卻又不像逆濾波那樣佈滿雪花。

實務上 Sn 與 Sf 很難精確得知，因此常把 Sn/Sf 直接當成可調參數 K:K 太小則雜訊被放大、影像顆粒粗糙;K 太大則還原不足、影像仍然模糊。7.2.2 節估計出的雜訊標準差，是設定 K 的重要參考起點。調參的過程，就是在銳利與乾淨之間找甜蜜點——這個尋找的過程，正是 Lab 7-2 的核心。

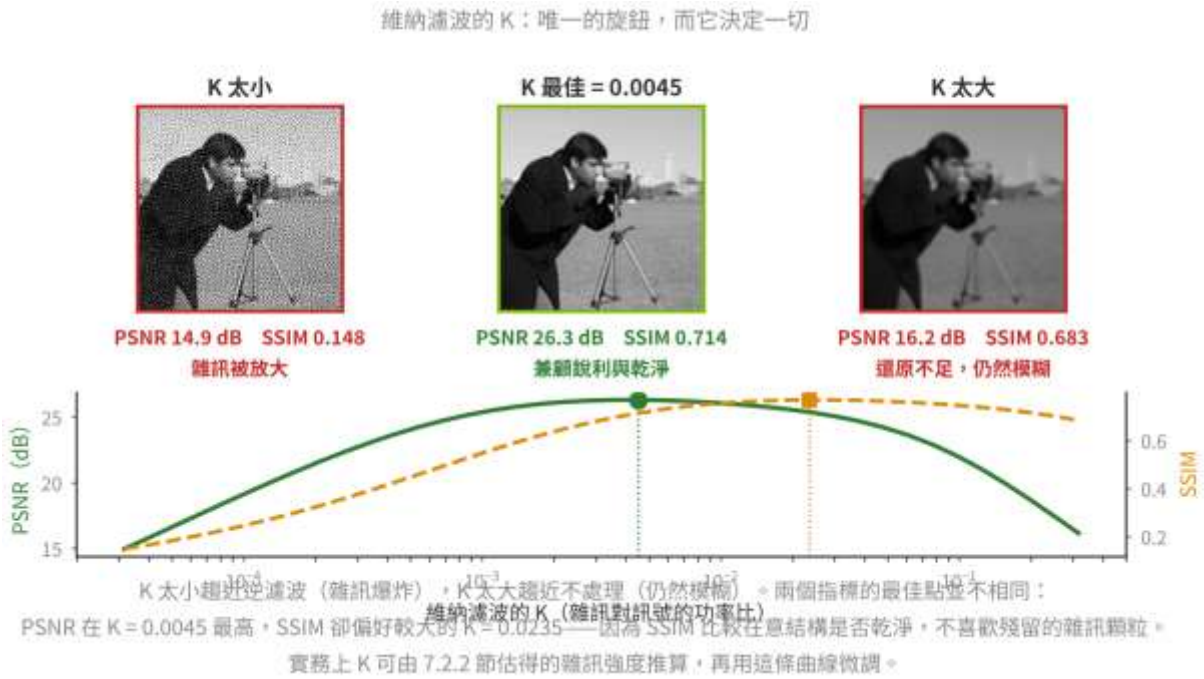


圖 7-17　維納濾波的 K：唯一的旋鈕，而它決定一切

程式 7-4 維納濾波反卷積實作

```
import cv2, numpy as np

def wiener_filter(img, psf, K=0.01):
    """維納濾波反卷積。img:退化影像;psf:退化函數;K:雜訊訊號比"""
    img = img.astype(np.float32)
    # 把 PSF 填補到與影像同尺寸並轉到頻率域
    psf_pad = np.zeros_like(img)
    kh, kw = psf.shape
    psf_pad[:kh, :kw] = psf
    psf_pad = np.roll(psf_pad, -kh // 2, axis=0)
    psf_pad = np.roll(psf_pad, -kw // 2, axis=1)
```

```
    H = np.fft.fft2(psf_pad)
    G = np.fft.fft2(img)

    # 維納公式:H* / (|H|^2 + K)
    W = np.conj(H) / (np.abs(H) ** 2 + K)
    F_hat = W * G

    out = np.abs(np.fft.ifft2(F_hat))
    return np.clip(out, 0, 255).astype(np.uint8)

# --- 實驗:製造模糊 + 雜訊,再還原 ---
clean = cv2.imread("clean.jpg", 0)
psf = cv2.getGaussianKernel(15, 3)
psf = psf @ psf.T                          # 15x15 高斯 PSF

blurred = cv2.filter2D(clean, -1, psf)
noisy = np.clip(blurred + np.random.normal(0, 5, clean.shape), 0, 255)

print("未還原(模糊+雜訊)PSNR:",
      cv2.PSNR(clean, noisy.astype(np.uint8)))

for K in [0.0001, 0.001, 0.01, 0.1]:
    restored = wiener_filter(noisy, psf, K)
    print(f"K={K}: PSNR = {cv2.PSNR(clean, restored):.2f} dB")
    cv2.imwrite(f"wiener_K{K}.png", restored)
```

7.5.3 約束最小平方濾波

維納濾波有個實務門檻：它需要知道 Sn/Sf，而這兩個功率譜通常都不知道。約束最小平方濾波(Constrained Least Squares)提供了另一條路：它只需要知道雜訊的平均值與變異數(比功率譜容易估計得多)，並把「還原結果應該平滑」這件事直接寫進最佳化目標。其轉移函數為：

$$F(u,v) = [\, H^*(u,v) / (\, |H(u,v)|^2 + \gamma \cdot |P(u,v)|^2 \,) \,] \cdot G(u,v)$$

其中 P 是拉普拉斯運算子的頻率響應(第 5 章的二階微分核),γ 是調節參數。比較兩式可以發現：維納濾波在分母加的是常數 K，約束最小平方加的則是隨頻率變化的 $\gamma|P|^2$。因為拉普拉斯在高頻的響應大，這等於「頻率愈高、抑制愈強」——把「不要產生劇烈震盪的結果」這個先驗知識，寫成了數學。這正是 7.1.3 節所說正則化的教科書範例：γ 就是正則化強度，調大則結果平滑但模糊，調小則銳利但可能出現雜訊與振鈴。



圖 7-18　維納濾波與約束最小平方的對照

7.5.4 反覆式反卷積：Richardson-Lucy

以上都是一次算完的線性方法，另有一類反覆逼近的非線性方法，代表是 Richardson-Lucy 演算法(Richardson 1972、Lucy 1974 分別在光學與天文領域獨立提出)。它假設 Poisson 雜訊模型(因此特別適合光子計數的天文與醫學影像)，從一個初始估計出發，每次反覆用「觀測影像除以目前估計的模糊結果」來修正估計，並保證每次結果都非負(符合光強度的物理意義，這是線性方法做不到的優點——維納濾波的輸出可能出現負值)。

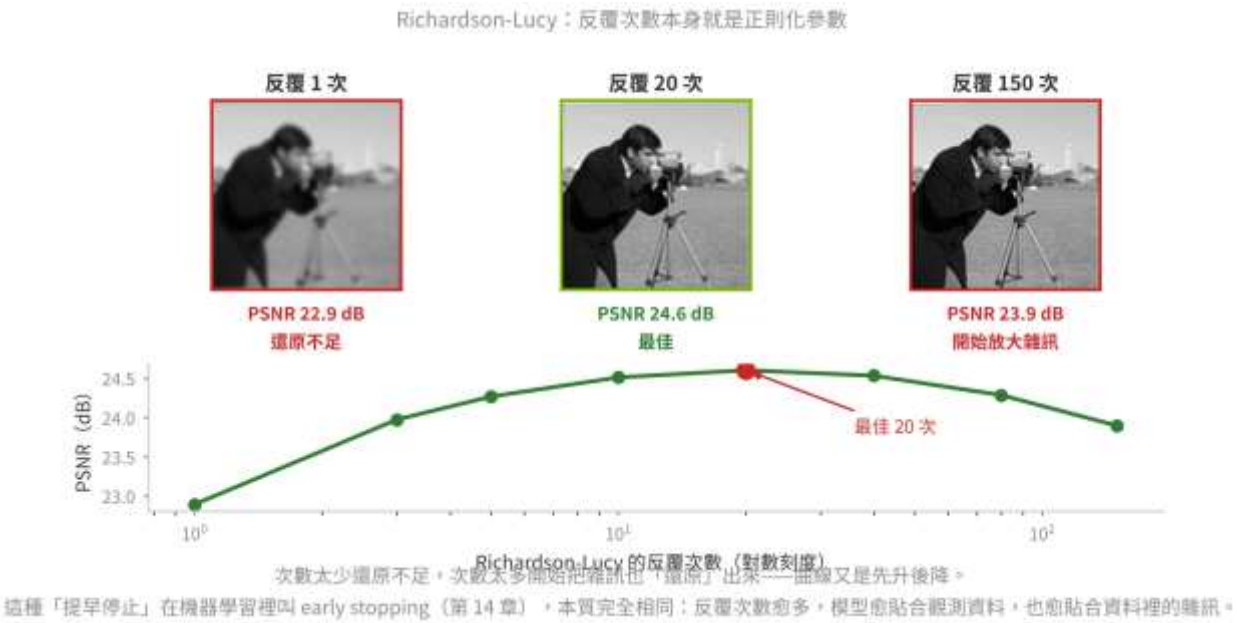


圖 7-19　Richardson-Lucy：反覆次數本身就是正則化參數

這正是叫獸開講中拯救哈伯望遠鏡的主力演算法之一。實務上有個關鍵抉擇：反覆次數。次數太少還原不足;次數太多則開始放大雜訊，影像出現不自然的顆粒與塊狀結構。天文學界處理哈伯早期影像時，經驗上約 50 次反覆能明顯改善影像品質、削減散射光暈又保留原始結構;超過 100 次後，物體的形狀反而開始崩壞、出現人造的塊狀質感。「知道何時停手」是所有反覆式還原演算法的共同課題，學界也發展出以廣義交叉驗證等準則自動決定停止時機的方法。

7.5.5 推導：維納濾波的公式是怎麼來的

7.5.2 節直接給出了維納濾波的轉移函數，但那個分母裡的 Sn/Sf 看起來頗為神祕。其實整條公式可以從一個很單純的要求推出來：我想要一個線性濾波器，使還原結果與真實影像的均方誤差最小。推導只需要三步，而且不需要任何高等數學。

第一步，設定問題。我們要找一個轉移函數 M(u, v)，使還原結果為 $\hat{F} = M \cdot G$。目標是讓誤差的期望值 $E[|\hat{F} - F|^2]$ 最小。由於每個頻率彼此獨立（這正是 7.1.5 節提到的好處），可以對每一個頻率各自求極小，問題瞬間變得容易。

第二步，展開誤差。把 $G = H \cdot F + N$ 代入：$\hat{F} - F = M \cdot (H \cdot F + N) - F = (M \cdot H - 1) \cdot F$

+ M·N。假設訊號與雜訊不相關（這是標準假設，意思是雜訊不會剛好跟影像內容同步變化），誤差的平方期望值就是兩項的和：$|M·H - 1|^2 \cdot Sf + |M|^2 \cdot Sn$，其中 Sf 與 Sn 分別是訊號與雜訊的功率譜。這個式子已經把取捨寫得很清楚了：第一項是「還原不足」的代價（M·H 偏離 1 多少），第二項是「放大雜訊」的代價。M 太小則第一項大，M 太大則第二項大。

第三步，求極小。把上式對 M 微分並令導數為零，整理後得到 $M = H^* / (|H|^2 + Sn/Sf)$，其中 H^* 是 H 的共軛複數。這就是 7.5.2 節的維納濾波公式。分母裡的 Sn/Sf 不再神祕——它就是「雜訊功率對訊號功率的比值」，也就是訊噪比的倒數。

公式到手之後，兩個極端情形特別值得檢查，因為它們印證了圖 7-14 的增益曲線。當某個頻率的雜訊可忽略（$Sn/Sf \to 0$）時，$M \to H^*/|H|^2 = 1/H$，退化成逆濾波——完全信任資料，全力還原。當雜訊遠大於訊號（Sn/Sf 很大）時，分母被這一項主導，$M \to 0$，也就是乾脆放棄這個頻率。維納濾波的全部智慧就在這兩個極端之間的自動切換，而切換的依據是每一個頻率各自的訊噪比。這也解釋了為什麼實務上把 Sn/Sf 簡化成常數 K 仍然好用：即使忽略了訊噪比隨頻率的變化，$|H|^2$ 這一項仍然會讓濾波器在 H 小的地方自動收手。

7.6 應用案例

7.6.1 案例一：MRI 醫學影像去噪

維納濾波在醫學影像領域有長期的應用傳統。以磁振造影(MRI)為例：掃描時間愈長，訊號累積愈多、訊噪比愈好，但病人必須維持不動、費用也愈高;工程上因此常以較快的掃描搭配後處理去噪。將維納濾波套用於含雜訊的 MRI 切片影像後，以 PSNR 量化比較處理前後的差異，是評估演算法成效的標準做法——處理後 PSNR 若提升數個 dB，即代表雜訊被有效抑制而結構資訊得以保留。

醫學影像的特殊要求也值得注意，而且是本案例最重要的教學點：過度平滑可能

抹去微小的病灶，把腫瘤的早期徵兆一起「濾掉」。更麻煩的是，這種錯誤在 PSNR 上幾乎看不出來——一個直徑十個像素的病灶，佔整張影像的比例微乎其微，把它抹平對全域 MSE 的影響小到可以忽略，PSNR 甚至可能因為背景更乾淨而上升。這說明了全域指標的根本盲點：它衡量的是平均表現，而醫療關心的是最壞情況。因此醫療應用的去噪往往寧可保守，並且必須經過臨床驗證與放射科醫師的視覺評估，不能只看 PSNR 好看就上線。

7.6.2 案例二：哈伯太空望遠鏡的 PSF 反卷積

叫獸開講中的哈伯救援，是「非盲反卷積」的教科書級案例，值得從工程角度再拆解一次。它成功的關鍵有三：

9. 退化函數可測量：天文學家可以觀測遙遠的恆星——那是完美的點光源，它在感光元件上留下的光斑，就是點擴散函數 PSF 的直接量測值。此外也可從光學設計反推理論 PSF，理論 PSF 的優點是不含雜訊。有了 h，問題從困難的盲反卷積降級為可解的非盲反卷積。
10. 雜訊模型明確：天文影像的主要雜訊是光子計數的 Poisson 雜訊，正好符合 Richardson-Lucy 的假設前提，演算法與物理模型高度契合。
11. 願意接受不完美：天文學家的目標不是「拍出好看的照片」，而是「量出正確的亮度與位置」。即使還原後的影像仍有殘餘偽影，只要科學量測的誤差在可接受範圍內，任務就算成功。

這個案例也暴露了實務的複雜性：哈伯的 PSF 並非位置不變(視野不同區域的 PSF 不同)，也非時間不變(太空船抖動、望遠鏡結構受熱脹冷縮影響，PSF 會在數十分鐘的尺度上緩慢改變)。這直接違反 7.1.2 節劣化模型的第一個假設，因此實務上必須分區塊、分時段建模——理論模型與工程現實之間的落差，永遠是工程師的主戰場。

7.6.3 案例三：產線運動模糊還原與下游任務

第三個案例最貼近本學程的場域。想像一條輸送帶，工件以每秒 0.5 公尺的速度

通過檢測站，相機曝光時間 2 毫秒——工件在曝光期間移動了 1 毫米。若影像的空間解析度是每像素 0.05 毫米，這代表每個點被抹成了 20 個像素長的線段：典型的水平運動模糊。結果是：第 9 章的邊緣偵測找不到清楚的工件輪廓，第 13 章的特徵匹配比對不上模板，第 16 章的 YOLO 信心值大幅下降，整條檢測線的誤判率飆升。

這個問題有三個層次的解法，依序是工程師應該考慮的優先順序：

12. 光學與機構層(最優先)：縮短曝光時間並加強打光(第 17 章的 AOI 光源設計)，或改用全域快門(Global Shutter)相機、加裝頻閃光源在極短時間內凍結畫面。這是治本之道——沒有模糊，就不需要還原。
13. 演算法層(次之)：若模糊無法避免，則運動模糊的退化函數其實是已知的!模糊方向由輸送帶方向決定，模糊長度等於「速度乘以曝光時間再除以像素尺寸」。編碼器的速度訊號與相機的曝光參數都是現成的資料，可以即時計算出 PSF，再用維納濾波還原。這是非盲反卷積在工業現場的漂亮應用。



圖 7-20　由產線參數推算運動模糊的 PSF 並還原

14. 學習層(最後)：若前兩者都受限，可考慮把運動模糊當成資料增強加入訓練集(第 15 章)，讓 YOLO 直接學會辨識模糊的工件。這是「與其還原資料以配合模型，不如訓練模型以適應資料」的思路轉換。

本案例的教學價值在於：影像還原不是孤立的技術練習，而是整個系統設計中的一環。一個好的視覺工程師，會先問「這個模糊能不能從源頭消除」，而不是一頭栽進演算法。

程式 7-5 由產線參數推算 PSF 並還原運動模糊

```
import cv2, numpy as np

def motion_psf(length, angle_deg):
    """產生運動模糊 PSF:length 為模糊長度(像素),angle 為方向"""
    psf = np.zeros((length, length), np.float32)
    psf[length // 2, :] = 1.0
    M = cv2.getRotationMatrix2D((length / 2 - 0.5, length / 2 - 0.5),
                                angle_deg, 1.0)          # 第 4 章的旋轉
    psf = cv2.warpAffine(psf, M, (length, length))
    return psf / psf.sum()

# --- 由產線參數推算 PSF(非盲反卷積的關鍵) ---
speed_mm_s   = 500.0    # 輸送帶速度(mm/s),來自編碼器
exposure_s   = 0.002    # 曝光時間(s),來自相機設定
pixel_mm     = 0.05     # 每像素代表的實際尺寸(mm),來自第 4 章相機校正

blur_len = int(round(speed_mm_s * exposure_s / pixel_mm))
print("推算模糊長度(像素):", blur_len)          # → 20

psf = motion_psf(blur_len, angle_deg=0)           # 水平運動

blurred = cv2.imread("part_blurred.png", 0)
restored = wiener_filter(blurred, psf, K=0.005)   # 沿用程式 7-4
cv2.imwrite("part_restored.png", restored)

# --- 驗證還原對下游任務的效益(第 9、13 章) ---
for name, im in [("模糊", blurred), ("還原", restored)]:
    edges = cv2.Canny(im, 80, 160)
    orb = cv2.ORB_create(1000)
    kps = orb.detect(im, None)
    print(f"{name}: 邊緣像素數 = {int(edges.sum() / 255)},"
          f" ORB 特徵點數 = {len(kps)}")
```

7.7 影像還原對後續處理的影響

影像還原很少是最終目的，它幾乎總是某個更大任務的前處理步驟。因此評估還原的價值，除了看 PSNR，更應該看它讓下游任務進步了多少。以下三個連結值得學生實際動手量化：

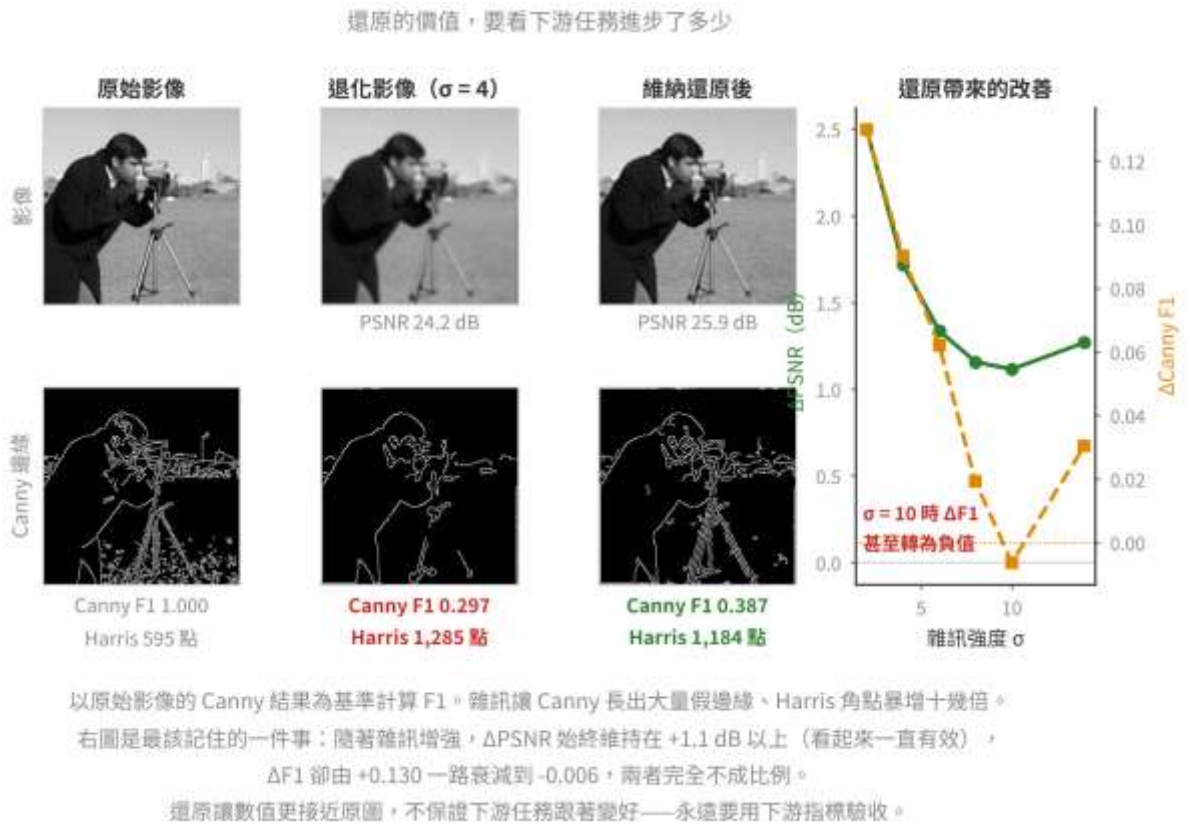


圖 7-21　還原的價值要看下游任務進步了多少

7.7.1 對邊緣偵測的影響(第 9 章)

Canny 邊緣偵測的第一步就是高斯平滑，原因正是「梯度運算會放大雜訊」——雜訊造成的局部劇烈變化，在微分後比真實邊緣還強。若影像雜訊嚴重，Canny 會產生大量細碎的假邊緣;若影像模糊，則邊緣的梯度峰值變得平坦，非極大值抑制難以精確定位，邊緣位置會產生偏移。良好的還原能同時改善這兩個問題，但過度平滑的還原(K 設太大)則會讓弱邊緣完全消失。這裡有一個實務準則：先想清楚下游要的是「完整的邊緣」還是「乾淨的邊緣」，再回頭調還原參數。

7.7.2 對特徵擷取的影響(第 13 章)

Harris 角點偵測依賴局部灰階在兩個方向上的變化量，模糊會直接降低角點響應值，使得許多真實角點落到門檻之下而被漏掉;雜訊則會在平坦區製造大量虛假的高響應點。SIFT 的情況更微妙：它本身就是在多尺度的高斯模糊金字塔上找極值，因此對輕微模糊有一定的耐受性，但嚴重模糊會使得特徵被偵測在錯誤的尺度上，描述子跟

著失真，匹配率大幅下降。ORB 使用的 FAST 角點偵測依賴中心像素與圓周上像素的亮度比較，對雜訊特別敏感——這也是程式 7-5 用 ORB 特徵點數作為還原成效指標的原因。

7.7.3 對深度學習模型的影響(第 15、16 章)

這是近年研究相當熱門的題目，結論可以歸納成三點。第一，分布偏移是主因：模型在乾淨影像上訓練，遇到模糊或含噪的測試影像時，準確率往往顯著下滑，因為輸入的統計特性已經偏離訓練分布。第二，還原不一定總是有幫助：如果還原演算法引入了訓練時未曾見過的偽影(如振鈴、過度銳化的邊緣光暈)，模型的表現可能不升反降——這是一個違反直覺但務必記住的陷阱。第三，資料增強常是更穩健的解法：在訓練時就加入模糊、雜訊、低光等劣化樣本，讓模型自己學會不變性，通常比在推論時做還原更可靠，運算成本也更低(不必為每一影格影像付出還原的代價)。

這三點合起來給出一個重要的工程判斷原則：若你能控制訓練流程，優先用資料增強;若你面對的是已經訓練好、無法重訓的模型，才考慮在前端加上還原模組，而且務必實測它是否真的提升了端到端的準確率，而不是想當然爾。

7.7.4 推導：為什麼雜訊對微分運算特別致命

7.7.1 節說「梯度運算會放大雜訊」，這是 Canny 要先做高斯平滑的理由。但放大多少?這件事可以算，而且答案會讓你對「先去雜訊再找邊緣」這條鐵則有完全不同的感受。

先看一階微分。離散的梯度運算是相鄰像素相減：$d = g(x+1) - g(x)$。設兩個像素的雜訊各自獨立、標準差皆為 σ，則相減之後雜訊的變異數相加，新的標準差為 $\sqrt{2}\cdot\sigma \approx 1.41\sigma$。乍看之下只放大了四成，似乎不嚴重。但關鍵不在雜訊本身變大多少，而在訊號與雜訊的比值：平坦區域的真實梯度接近零，微分後那裡只剩下 1.41σ 的純雜訊;而一條弱邊緣的梯度可能只有 3σ 到 5σ。也就是說，微分把「訊號很大、雜訊很

小」的局面，變成了「兩者同一個量級」。

二階微分更誇張。拉普拉斯核 [1, −2, 1] 的係數平方和為 1 + 4 + 1 = 6，因此輸出雜訊的標準差是 √6·σ ≈ 2.45σ。若用二維的五點拉普拉斯（中心 −4、四鄰各 1），係數平方和為 16 + 4 = 20，雜訊標準差變成 √20·σ ≈ 4.47σ。而真實的二階微分在平坦區與緩慢漸變區同樣接近零——於是第 5 章的拉普拉斯銳化在含雜訊影像上會產生滿屏顆粒，原因就在這個 4.47 倍。

高斯平滑的作用則恰好相反。對一個標準差為 σ 的雜訊做歸一化的加權平均，輸出雜訊的標準差會縮小為 σ 乘上「權重的平方和開根號」。以 sigma = 1 的高斯核為例，這個係數約為 0.4;sigma = 2 時約為 0.28。把它與微分的放大倍率相乘，就得到整條管線的淨效果——這正是 Canny 的 sigma 參數在調的東西：sigma 太小，微分的放大贏過平滑的壓制，假邊緣滿天飛;sigma 太大，弱邊緣的梯度被平滑掉而低於門檻，真邊緣漏掉。

最後把這個推導接回本章。7.4.2 節說「還原是受控的高通增強」，而高通增強與微分在頻率域是同一類操作——兩者都在放大高頻，也就都在放大雜訊。這解釋了為什麼本章的每一個方法（半徑受限、維納的 K、RL 的反覆次數）最後都在做同一件事：決定高頻要放大到哪裡為止。而圖 7-21 的實驗更進一步顯示，這個決定該由下游任務來做，不該由 PSNR 來做。

7.8 AI 影像修復：從還原到生成

近年來，深度學習徹底改寫了影像還原的版圖。以卷積神經網路或 Transformer 訓練的去噪、去模糊、超解析度模型(如 SRCNN、ESRGAN、Real-ESRGAN 及各式擴散模型)，在視覺品質上遠勝傳統方法，老照片修復、影片重製、手機的超解析變焦都已是成熟商品——叫獸開講中馬蓋先片頭的 4K 重生，正是這類技術的成果。

從 7.1.3 節正則化的觀點看，深度學習的突破其實很好理解：傳統方法的先驗知識

是人工設計的(「影像應該平滑」、「梯度應該稀疏」)，而深度模型是從數百萬張自然影像中「學」出先驗——它知道人臉長什麼樣、磚牆的紋理如何、樹葉的邊緣有多銳利。當這個先驗遠比人工設計的更貼近真實世界，還原品質自然大幅躍升。

影像補繪(Inpainting)則處理「缺一塊」的問題：移除照片中的路人、修補老照片的裂痕、去除浮水印。傳統方法(OpenCV 的 cv2.inpaint，提供 Telea 與 Navier-Stokes 兩種演算法)從破損區域邊緣向內推進，以周圍的紋理與梯度填補，適合小面積修補;生成式 AI 則能「想像」出整片合理的內容，面積再大也填得出來。

7.8.1 還原，還是腦補?

這裡必須劃下一條重要的界線。傳統反卷積是在「解方程式」：它只使用觀測資料與已知的物理模型，還原出的每一個細節，理論上都來自原始影像中殘存的資訊。生成式 AI 則是在「猜答案」：它根據訓練資料學到的先驗知識，產生一個「看起來最合理」的高解析度版本。兩者的差異在娛樂用途上無關緊要——馬蓋先的臉多了幾根不存在的頭髮不影響懷舊;但在司法鑑識、醫學診斷、科學量測上就性命攸關：AI 放大的車牌號碼可能是憑空編造的，AI 補全的病灶邊界可能誤導手術。

曾有廣為流傳的案例顯示，某些人臉超解析度模型在放大低解析度的人臉時，會產生與原本族裔特徵不符的結果——因為模型輸出的是「訓練資料中最常見的臉」，而不是「這個人的臉」。這提醒我們：生成模型的偏誤會忠實地反映訓練資料的偏誤，而使用者往往因為結果「看起來很清楚」就誤以為它很準確。清晰度不等於正確性，這是 AI 時代影像工程師必須內化的第一戒律。

身為工程師，你必須永遠能回答一個問題：這個像素的資訊，是「找回來的」還是「編出來的」?在交付任何經 AI 處理的影像時，誠實標註處理流程，是專業倫理的一部分。這也是叫獸開講思考題的核心。

7.9 本章與全書的觀念連結總表

相關章節	共用的觀念	本章的延伸或差異
第 3 章 數位影像基礎	MSE、PSNR、SSIM;RAW 高位元深度	作為還原成效的客觀驗收工具;RAW 為最佳還原輸入
第 5 章 空間域強化	平滑濾波、銳化、多影格平均	由主觀好看轉為依雜訊模型的統計最佳估計
第 6 章 頻率域處理	低通、高通、陷波濾波;卷積定理	模糊即低通、還原即受控高通;週期雜訊直接沿用陷波
第 9 章 影像分割	Canny 的高斯平滑、梯度運算	雜訊生假邊緣、模糊使邊緣定位偏移
第 10 章 二值影像處理	最大值/最小值濾波	即型態學的膨脹與侵蝕，一體多面
第 13 章 特徵擷取	Harris、SIFT、ORB 的局部灰階變化	模糊降低角點響應、雜訊製造假特徵
第 15、16 章 深度學習	資料分布、資料增強	還原作為前處理 vs. 劣化作為增強的取捨
第 17 章 邊緣部署	運算成本、即時性	FFT 與反覆式演算法的算力預算評估

表 7-2 第 7 章與全書其他章節的觀念連結

程式實作 Lab 7

Lab 7-1 雜訊診斷與濾波器配對

目標：建立「先診斷、再開藥」的工作習慣。(a)以程式 7-1 對同一張乾淨影像分別加上高斯、椒鹽與 Poisson 雜訊;(b)取平坦區域繪製直方圖，驗證三種雜訊的分布特徵，並用兩種方法估計高斯雜訊的標準差，比較估計值與真值;(c)對三張雜訊影像分別套用均值、高斯、中值、雙邊、非局部平均五種濾波，製作 3×5 的 PSNR 與 SSIM 比較表;(d)寫出結論：哪種雜訊該配哪種濾波器?為什麼中值濾波對高斯雜訊沒有特別優

勢，對椒鹽卻近乎完美?(e)挑戰題：自行實作自適應中值濾波，在椒鹽雜訊密度 5%、20%、40% 三種情況下與固定核中值濾波比較，繪製「雜訊密度對 PSNR」曲線。

Lab 7-2 維納濾波與醫學影像去噪

目標：重現 7.6.1 節的 MRI 去噪實驗流程。(a)取公開的 MRI 或 CT 切片影像(或以任意灰階醫學影像替代)，加入已知強度的高斯雜訊作為模擬退化影像;(b)以程式 7-4 的維納濾波處理，掃描參數 K 從 0.0001 到 0.5，繪製「K 對 PSNR」的曲線，找出最佳 K 值;(c)將最佳結果與非局部平均去噪比較 PSNR 與 SSIM，並附上局部放大截圖;(d)在原圖中人工加入一個直徑約十像素的低對比小圓點模擬病灶，重跑一次流程，觀察 PSNR 最佳的參數是否會把它抹掉——驗證 7.6.1 節提到的「全域指標盲點」;(e)討論題：PSNR 最高的結果，在醫師眼中是否就是最好的影像?為什麼醫學影像處理不能只看數字?

Lab 7-3 產線運動模糊還原與下游任務評估

目標：完成 7.6.3 節的完整工程流程，並量化還原對下游任務的效益。(a)取一張清晰的工件或零件照片，以程式 7-5 的 motion_psf 製造已知長度與角度的運動模糊，再加入少量高斯雜訊;(b)假裝你不知道真實參數，改由「模擬的產線參數」(自訂速度、曝光時間，並用第 4 章相機校正得到的像素尺寸)推算 PSF，以維納濾波還原;(c)比較三種影像——原始、模糊、還原——在下列三項下游任務的表現：Canny 邊緣像素數與視覺完整度、ORB 特徵點數與對原圖的匹配成功率、以及(若已學到第 16 章)YOLO 偵測的信心值;(d)刻意把推算的模糊長度設錯正負 30%，觀察還原品質如何惡化，體會「PSF 估計準確度」的重要性;(e)分組討論題：承 7.6.3 節的三個層次，若你是這條產線的工程師，實際會怎麼做?請列出成本、可行性與效益的評估。

Lab 7-4 反卷積三兄弟的參數掃描

目標：親手畫出三條「先升後降」的曲線，把正則化這個抽象概念變成你量過的數據。(a)取一張乾淨影像，以已知的高斯 PSF 製造模糊，再加入已知強度的高斯雜

訊;(b)實作半徑受限逆濾波，掃描 D0 由 5 到 125，畫出 D0 對 PSNR 的曲線並找出峰值;(c)實作維納濾波，掃描 K 由 1e-5 到 1，同時畫出 PSNR 與 SSIM 兩條曲線——確認兩者的最佳點不在同一個地方，並解釋為什麼;(d)實作 Richardson-Lucy，掃描反覆次數 1 到 200，畫出曲線並找出最佳次數;(e)把三條曲線放在同一張圖上（橫軸各自正規化到 0 至 1），觀察它們的形狀有多相似;(f)改變雜訊強度重做一次，記錄「雜訊愈大，最佳參數往哪個方向移動」，並解釋這個趨勢;(g)寫下結論：如果只能用一句話告訴學弟妹怎麼調這些參數，你會說什麼?

Lab 7-5 退化函數估錯的代價

目標：理解非盲反卷積「非盲」兩個字的份量。(a)以已知長度 L 與角度 θ 的運動模糊 PSF 製造退化影像;(b)用正確的 L 與 θ 做維納還原，記錄 PSNR 作為基準;(c)固定 θ 正確，把 L 由正確值的一半掃到兩倍，畫出「L 的誤差對 PSNR」的曲線;(d)固定 L 正確，把 θ 由正確值掃到正負 30 度，畫出對應的曲線——比較兩條曲線的陡峭程度，判斷哪一個參數估錯的代價比較大;(e)觀察估錯時的還原影像有什麼特徵（提示：留意有沒有方向一致的條紋或鬼影），並說明你能不能從還原結果本身看出參數估錯了;(f)進階：試著只從模糊影像的頻譜反推 L（提示：利用習題 21 的通式，量測頻譜暗帶的間距），與真值比較;(g)寫下你的結論：在產線上，你會把力氣花在「取得準確的 PSF 參數」還是「改進還原演算法」?

Lab 7-6 還原到底有沒有幫到下游

目標：重現圖 7-21 的實驗，並建立「用下游指標驗收前處理」的工作習慣。(a)取一張乾淨影像，計算它的 Canny 邊緣作為基準答案，並記錄 Harris 角點數;(b)製造一組退化影像，雜訊強度由小到大共六級;(c)對每一級都做維納還原（每一級都要重新掃描最佳 K，不可共用同一個 K——想想為什麼）;(d)對退化影像與還原影像分別計算 Canny 的 F1 分數（以步驟 a 的結果為基準）與 Harris 角點數;(e)畫出「雜訊強度對 ΔPSNR」與「雜訊強度對 ΔF1」兩條曲線，找出 ΔF1 開始失效的位置;(f)把下游任務

換成第 13 章的 ORB 特徵匹配（以還原影像對乾淨影像做匹配，記錄成功匹配的點數），重做一次;(g)最後寫一段兩百字的建議書，對象是產線主管：在什麼條件下值得加上還原模組、在什麼條件下不值得，以及你的判斷依據是什麼。這一題的目的不是演算法，而是工程判斷。

本章重點整理

- 影像強化追求主觀好看且不需先驗知識，影像還原則基於劣化模型 g = h * f + n 客觀反推原始影像;頻率域形式為 G = H·F + N。
- 還原是逆問題，常為病態問題(解不連續依賴資料);解法的共通策略是正則化——以先驗知識約束解的形態。
- 模糊即低通濾波，還原即受控的高通增強;與第 5 章 High-Boost、第 6 章高頻強調同屬提升高頻，差別在於增益是否依退化函數量身訂做。提升高頻必然放大雜訊，是本領域的根本矛盾。
- 雜訊型態：高斯(鐘形)、椒鹽(兩端尖峰)、均勻、Poisson(變異數等於平均值)、乘性/斑點、週期性;以平坦區直方圖辨識，以樣本標準差或拉普拉斯殘差估計參數。
- 去雜訊工具：均值家族(算術、幾何、諧波、反諧波)、排序統計家族(中值、最大、最小、alpha 修剪)、自適應濾波(局部降噪、自適應中值)、非局部平均(利用自相似性)。
- 逆濾波 $\hat{F} = G/H$ 因 H 趨近零時放大雜訊而失敗;維納濾波在分母加入常數 K(雜訊訊號比)，約束最小平方則加入 $\gamma|P|^2$(拉普拉斯正則化)，兩者皆為病態問題的正則化解。
- Richardson-Lucy 為反覆式非線性反卷積，假設 Poisson 雜訊並保證非負;反覆次數過多會放大雜訊，哈伯影像經驗上約 50 次為佳，超過 100 次影像開始崩壞。

- 還原品質直接影響下游：雜訊使 Canny 產生假邊緣、模糊使邊緣定位偏移與特徵點漏檢;對深度學習模型，資料增強常比推論時還原更穩健，且還原引入的偽影可能反而降低準確率。
- AI 修復與生成式補繪效果驚人，但屬於「依學到的先驗猜測」而非「依觀測資料還原」;清晰度不等於正確性，司法、醫療、科學量測場合必須嚴格區分並誠實標註處理流程。

習題

1. 影像強化與影像還原的目標與驗收方式有何不同?各舉一例，並說明兩者對先驗知識的需求差異。

   提示與參考解答：強化追求主觀視覺效果(如直方圖等化讓夜景變亮)，不需知道劣化原因;還原追求逼近原始影像(如維納濾波去除已知的運動模糊)，需要退化函數與雜訊統計量。驗收上強化多靠人眼或下游任務表現，還原則可用 PSNR、SSIM 客觀量化。可參考表 7-1。

2. 寫出空間域與頻率域的影像劣化模型，說明各符號的物理意義，並列出這個模型的三個隱含假設。

   提示與參考解答：空間域 $g = h * f + n$;頻率域 $G = H \cdot F + N$。f 為原始影像、h 為退化函數(PSF)、n 為加性雜訊、g 為觀測影像。三個假設為：退化線性且位置不變、雜訊為加性且與訊號獨立、雜訊零均值。實務上鏡頭邊緣模糊較嚴重違反第一項，Poisson 雜訊違反第二項，感測器暗電流違反第三項。

3. 什麼是適定問題的三個條件?影像還原最常違反哪一個?這在工程上造成什麼後果?

   提示與參考解答：解存在、解唯一、解對資料連續依賴。還原最常違反第三條：退化函數在高頻趨近零，還原時要乘上極大倍數，觀測資料中的微小雜訊被同等放大，造成輸出佈滿雪花。應對策略為正則化。

4. 什麼是盲反卷積?為什麼它比非盲反卷積困難?請從解的唯一性說明。

   提示與參考解答：盲反卷積指退化函數 h 未知，需同時估計 h 與 f。困難在於解不唯

一：「清楚影像配大模糊核」與「稍模糊影像配小模糊核」可產生相同的觀測結果，必須靠額外先驗(如自然影像梯度分布的稀疏性)才能收斂到合理解。

5. 如何從直方圖判斷一張影像受到的是高斯雜訊、椒鹽雜訊還是均勻雜訊?請描述完整的診斷步驟。

   提示與參考解答：步驟：先選取一塊本該平坦均勻的區域(純色背景、天空、工件平整面)，取出該區像素繪製直方圖。鐘形對稱分布為高斯;中央分布正常但兩端出現孤立尖峰為椒鹽;矩形平坦分布為均勻。若比較亮區與暗區，變異數隨平均亮度成正比增加則為 Poisson。

6. Poisson 雜訊與高斯雜訊最大的差別是什麼?這個特性對低光攝影有何影響?與第 5 章的夜景模式有何關聯?

   提示與參考解答：Poisson 雜訊的變異數等於平均值，強度隨訊號變化(訊號相關)，不符合「加性且獨立」的假設。低光時訊號弱，雖然雜訊絕對值小，但訊噪比更差。第 5 章夜景模式以多影格平均提升訊噪比，平均 N 張後雜訊標準差降為原來的 N 平方根分之一，正是對抗此類隨機雜訊的標準做法。

7. 自適應中值濾波相較固定核中值濾波的兩項改良是什麼?在什麼情況下差距最明顯?

   提示與參考解答：第一，若中位數本身是雜訊(0 或 255)則擴大視窗重試，解決高密度雜訊下中位數失效的問題;第二，若中心像素本身不是雜訊則原值保留，完全保護乾淨像素與細節。雜訊密度愈高(20% 以上)差距愈明顯，因為固定核在此時中位數常常也是雜訊。

8. 非局部平均利用了自然影像的什麼特性?請舉出兩種特別適合它發揮的影像內容，以及一種不適合的情況。

   提示與參考解答：利用自相似性：相似的紋理區塊在影像各處反覆出現。適合磚牆、織品紋理、規律的建築立面、草地等重複性高的內容。不適合的情況：內容高度獨特無重複結構的影像，或需要即時處理的場合(運算量大)。

9. 推導 F̂ = G/H 在含雜訊時的展開式，說明逆濾波失敗的數學原因，並說明「半徑受限逆濾波」如何補救及其副作用。

   提示與參考解答：將 G = H·F + N 代入得 F̂ = F + N/H。H 在高頻趨近零時 N/H 發

散。半徑受限逆濾波只在頻譜中心半徑 D0 內執行除法，相當於逆濾波加低通，但 D0 靠試誤決定，且頻域的硬截斷會造成第 6 章所述的振鈴效應。

10. 比較維納濾波與約束最小平方濾波的轉移函數，說明兩者分母的差異代表什麼樣的先驗知識。

    提示與參考解答：維納分母為 $|H|^2 + K$(常數，代表雜訊訊號功率比);約束最小平方分母為 $|H|^2 + \gamma|P|^2$,P 為拉普拉斯的頻率響應，高頻響應大，等於「頻率愈高抑制愈強」，把「還原結果不應劇烈震盪」的平滑先驗寫進數學。兩者都是正則化，差別在正則化項是否隨頻率變化。

11. 維納濾波公式中的 K 值調大或調小，分別對還原結果造成什麼影響?應如何決定起始值?

    提示與參考解答：K 太小接近逆濾波，還原銳利但雜訊被放大、影像顆粒粗糙;K 太大則過度抑制高頻，還原不足、影像仍模糊。起始值可由 7.2.2 節估得的雜訊標準差推估雜訊功率，再對照影像本身的功率;實務上以掃描 K 值並觀察 PSNR 曲線找極大值(見 Lab 7-2)。

12. Richardson-Lucy 演算法有哪兩項相對於線性方法的優點?為什麼反覆次數不是愈多愈好?

    提示與參考解答：優點：假設 Poisson 雜訊模型，適合光子計數影像(天文、醫學);每次反覆保證結果非負，符合光強度物理意義(維納濾波輸出可能為負)。反覆次數過多會放大雜訊，產生不自然的顆粒與塊狀結構;哈伯經驗約 50 次為佳，超過 100 次形狀開始崩壞。

13. 為什麼說「模糊是低通濾波、還原是高通增強」?本章的反卷積與第 5 章的 Unsharp Masking、第 6 章的高頻強調濾波，三者有何異同?

    提示與參考解答：模糊把高頻振幅壓低即低通;還原要把高頻補回即高通增強。三者相同處：都提升高頻、都會放大雜訊。相異處：Unsharp Masking 的增益由使用者主觀設定的 k 決定;高頻強調由濾波器形狀決定;反卷積的增益由退化函數 H 精確決定，是量身訂做的補償。可參考 7.4.2 節與表 7-2。

14. 影像還原對第 9 章的 Canny 邊緣偵測與第 13 章的 ORB 特徵擷取分別有何影響?請說明雜訊與模糊各自造成的問題。

提示與參考解答：雜訊：梯度運算放大雜訊，Canny 產生大量細碎假邊緣;ORB 的 FAST 角點依賴中心與圓周像素亮度比較，雜訊會製造大量虛假特徵點。模糊：梯度峰值變平坦，非極大值抑制難以定位，邊緣位置偏移;角點響應值下降，真實角點落到門檻之下被漏檢，匹配率下降。

15. 對一個已訓練好的 YOLO 模型，在推論前加上影像還原模組，是否一定會提升準確率?請說明三種可能情況。

提示與參考解答：不一定。情況一：還原減輕分布偏移，準確率提升。情況二：還原引入訓練時未見過的偽影(振鈴、過度銳化光暈)，反而使輸入更偏離訓練分布，準確率下降。情況三：還原的運算成本使系統無法即時處理，實際部署效益為負。較穩健的做法是在訓練階段以劣化樣本做資料增強，見 7.7.3 節。

16. 承 7.6.3 節，若產線工件的運動模糊長度為 20 像素，身為工程師你會依什麼順序考慮解法?請說明每個層次的具體做法。

提示與參考解答：順序為光學機構層、演算法層、學習層。光學機構層(治本)：縮短曝光時間並加強打光、改用全域快門相機、加裝頻閃光源凍結畫面。演算法層：由編碼器速度、曝光時間與像素尺寸推算 PSF，以維納濾波做非盲反卷積。學習層：將運動模糊作為資料增強加入訓練集，讓模型直接適應。

17. (思辨題)監視器畫面經 AI 超解析度處理後在法庭上作為證據，你贊成嗎?請以本章「還原 vs. 腦補」的區分，提出至少三點論證。

提示與參考解答：本題無標準答案，評分重點在論證品質。可能論點包括：傳統反卷積只使用觀測資料與物理模型，細節來自殘存資訊;生成式模型輸出「最合理的猜測」，可能產生原本不存在的細節;模型的訓練資料偏誤會反映在輸出上(如人臉超解析度改變族裔特徵);清晰度不等於正確性，而清晰的影像對陪審團有過度的說服力;可主張區分「可採信的還原」與「僅供參考的重建」，並要求揭露完整處理流程與演算法。

18. 承圖 7-3 與圖 7-15：逆濾波在「完全沒有外加雜訊」的情況下，為什麼還是會失敗?本書實測的結果是：一個雜訊都沒加，還原結果的數值已經跑到 −1,709 到 1,960。請解釋這個現象的來源，並說明它對「病態問題」這個概念的意義。

提示與參考解答：來源是浮點運算本身的捨入誤差。雙精度浮點數的相對精度約為 1e-16，也就是說每一次運算都會引入這個量級的誤差;而逆濾波要做的是除以 H，在高頻處 |H| 可能小到 1e-10 以下，於是 1e-16 的誤差被放大成 1e-6 的相對誤差，乘上影像頻譜本身的大數值後，絕對誤差就達到上千。它對「病態」的意義非常直接：7.1.3 節說病態的定義是「解不連續依賴資料」，而這個實驗顯示所謂的「資料擾動」不必來自感測器——光是計算機表示數字的有限精度就已經足夠。換句話說，這個問題在數學上就無解，不是換一台更好的電腦、用更高的精度就能解決的。唯一的出路是正則化：放棄「完全忠實於資料」，改成「在忠實與穩定之間取平衡」——這正是維納濾波在做的事。

19. 承圖 7-8 的濾波器配對矩陣：請說明為什麼(a) 非局部平均在椒鹽雜訊上幾乎毫無作用;(b) 中值濾波對高斯雜訊的效果不如非局部平均;(c) 陷波濾波對隨機雜訊是負的，對週期性雜訊卻一舉領先。

    提示與參考解答：(a) 非局部平均的運作方式是「找出與目標區塊相似的區塊再加權平均」，而相似度是以區塊間的均方差計算。椒鹽雜訊會在區塊中造成 0 與 255 的極端值，使均方差被少數幾個像素主導，導致相似的區塊被判定為不相似、不相似的被判定為相似——權重算錯了，平均自然沒有意義。它的假設前提是加性高斯雜訊。(b) 中值濾波取的是排序後的中間值，對高斯雜訊而言這只用到了一個樣本的資訊，而非局部平均用的是數百個相似區塊的加權平均，依大數法則雜訊被壓低得多;此外中值濾波會抹掉細線與角點，額外損失細節。(c) 陷波濾波的原理是「在頻譜上挖掉少數孤立亮點」。隨機雜訊的能量均勻散布在整個頻譜上，沒有孤立亮點可挖，挖掉的反而是影像本身的頻率成分，所以是負的;週期性雜訊則恰好相反，它的全部能量集中在少數幾個點上，挖掉就乾淨了，而影像的其餘頻率完好無損。這整張表的訊息是：每一種工具都只在一種情況下最強，所以 7.2.2 節的診斷不是可有可無的前置作業，而是決定成敗的那一步。

20. 承圖 7-10：自適應局部降噪濾波的核心公式是輸出 = g − (σn² / σL²) × (g − μL)，其中 σn² 是雜訊變異數、σL² 與 μL 是局部變異數與局部平均。請說明這個比值在平坦區與邊緣處各是多少，以及為什麼公式要寫成這個形式。若 σn² 估得太大會怎樣?

    提示與參考解答：在平坦區，原始訊號幾乎是常數，局部變異數 σL² 主要來自雜訊，因此 σL² ≈ σn²，比值接近 1，輸出 ≈ g − (g − μL) = μL，也就是完全交給局部

平均，全力平滑。在邊緣或紋理處，σ_L^2 遠大於 σ_n^2，比值趨近 0，輸出 $\approx g$，也就是幾乎原樣保留。公式寫成這個形式的巧妙之處在於：它不是用一個門檻去硬性切換兩種行為，而是讓平滑的強度隨著「這裡有多少真實訊號」連續變化，因此不會在門檻附近產生突兀的接縫。若 σ_n^2 估得太大（例如在邊緣上量雜訊，如圖 7-6 的錯誤示範），比值會在所有地方都接近 1，濾波器退化成普通的均值濾波，邊緣也被抹掉——這就是為什麼 7.2.2 節的參數估計必須做對。實作上通常還會加一道保險：把比值夾在 0 到 1 之間，避免 σ_L^2 小於 σ_n^2 時出現大於 1 的比值而把影像推過頭。

21. 承圖 7-12 與 7-13：運動模糊的頻率響應在哪些頻率上等於零?請推導通式。本書實測模糊長度 L = 9、影像邊長 N = 256 時，殘差的頻譜尖峰落在 28.4、56.9、85.3，請驗證這組數字。

    提示與參考解答：長度 L 的均勻運動模糊，其 PSF 在空間域是一個寬度 L 的矩形。矩形的傅立葉轉換是 sinc 函數，而 $\mathrm{sinc}(x) = \sin(\pi x)/(\pi x)$ 在 x 為非零整數時等於零。換算到離散頻率座標：$H(u)$ 在 $u \cdot L/N$ 為非零整數時為零，也就是 $u = N \cdot k / L$（$k = 1, 2, 3, \ldots$）。驗證：N = 256、L = 9 時，$u = 256/9 = 28.4$、$512/9 = 56.9$、$768/9 = 85.3$——與圖 7-13 量到的殘差尖峰位置完全吻合。這個通式有兩個實務用途。其一是診斷：若你不知道模糊長度，可以從模糊影像的頻譜上找出暗帶的間距反推 L，這是盲反卷積估計 PSF 的入門做法。其二是預警：L 愈大，零點愈密集、落在愈低的頻率上，代表愈多的低頻資訊被徹底抹除;L = 9 時第一個零點在 28，L = 30 時就掉到 8.5，影像能量最集中的區域都被挖空了。

22. 承圖 7-13：本書實測發現，在退化程度相當的條件下，有零點的運動模糊還原後的 PSNR（27.0 dB）反而高於無零點的高斯失焦（25.4 dB）。這與「有零點就救不回來」的直覺相反，請解釋為什麼，並說明兩者真正的差別在哪裡。

    提示與參考解答：關鍵在於「零點」與「整體衰減」是兩件事。高斯的 $|H|$ 沒有零點，但它單調遞減且衰減得非常快，到了中頻就已經壓到極小——換句話說它把「大部分頻率」都衰減得很嚴重，每一個頻率都只剩一點點資訊可以放大。運動模糊的 sinc 則是在零點之間仍然保持相當的響應，只有零點那幾條窄帶被完全抹除;其餘頻帶的資訊保存得相對完整，還原起來反而容易。所以 PSNR 比較高是合理的。真正的差別在殘差的形狀：高斯的還原誤差均勻散布在所有頻率，表現為整體略糊;運動模糊的誤差集中在 N/L 的倍數上（圖 7-13 右側的尖峰），表現為有固定方向與週期的結構性偽影。這個差別在工程上很重要：均勻的糊通常只是不好看，但有

結構的偽影可能被下游的邊緣偵測或特徵擷取誤判為真實結構。這題的教訓是：不要把課本上的定性說法當成定量結論，實際量一次往往會發現事情比口訣複雜。

23. 承圖 7-16、7-17、7-19：半徑受限逆濾波的 D0、維納濾波的 K、Richardson-Lucy 的反覆次數，三條曲線都是「先升後降」。請說明這三個參數在數學上扮演的是同一個什麼角色，並各舉一個其他領域的對應例子。

    提示與參考解答：三者扮演的都是正則化強度（regularization strength），也就是在「忠實於觀測資料」與「解要夠平滑、夠穩定」之間的權衡旋鈕。往一邊走是完全相信資料，結果被雜訊主導（過度擬合）;往另一邊走是過度約束，結果過於平滑而丟失真實細節（欠擬合）。最佳點永遠在中間，所以曲線必然先升後降。三者的對應關係：D0 以「只相信低頻」的方式限制解的複雜度;K 以「在分母加一個常數」的方式限制增益的上限;RL 的反覆次數則是以「還沒來得及擬合雜訊就停手」的方式達到同樣效果。其他領域的例子：機器學習的 L2 正則化係數（第 14 章）、神經網路訓練的提早停止（early stopping，第 15 章）、以及第 5 章銳化強度 k 的選擇。認出這個共通結構很有價值：一旦你知道某個參數扮演的是正則化角色，你就知道該怎麼調它——掃一遍、畫出曲線、取峰值，而不是憑感覺微調。

24. 承圖 7-21：本書實測發現，隨著雜訊增強，維納還原的 ΔPSNR 始終維持在 +1 dB 以上，ΔCanny F1 卻由 +0.130 一路衰減到 −0.006。請解釋為什麼兩者會脫鉤，並說明這對「還原要不要做」這個決策有什麼啟示。

    提示與參考解答：脫鉤的原因在於兩個指標衡量的是不同的東西。PSNR 衡量的是逐像素的數值誤差總量，而維納濾波的目標函數正是最小均方誤差——它在設計上就是為了讓這個數字變好，所以當然一直有效。Canny 的 F1 衡量的則是「邊緣位置是否正確」，它對兩件事特別敏感：殘留的雜訊顆粒會產生假邊緣，而過度平滑會讓弱邊緣的梯度落到門檻之下而漏掉。雜訊強時，維納濾波為了壓制雜訊必須用較大的 K，結果是數值誤差變小（PSNR 進步）但邊緣也被一起抹平（F1 退步），兩者於是反向。對決策的啟示有三點。其一，驗收指標必須與實際任務一致：若下游是邊緣偵測，就該用 F1 調參數，而不是用 PSNR。其二，還原不是免費的——它要花運算時間（第 17 章的預算問題），若換來的下游改善接近零甚至為負，就不該做。其三，更根本的做法往往是回到源頭：與其事後還原，不如改善打光、縮短曝光、換感測器（7.6.3 節把這一點列為最優先）。

25. (綜合設計題)某醫院要導入一套 MRI 影像後處理流程，目的是縮短掃描時間（代價是訊噪比下降），再以演算法補回品質。請設計這套流程的驗收方案：(a) 你會用哪些指標?為什麼不能只用 PSNR?(b) 如何設計實驗才能發現「演算法把微小病灶一起濾掉」這種錯誤?(c) 這套系統在臨床上線前，你認為最大的風險是什麼?(d) 若改用深度學習的去噪模型，你的驗收方案要增加哪些項目?

    提示與參考解答：本題無標準答案，評分重點在風險意識的完整性。(a) 至少三類指標：全域指標（PSNR、SSIM）作為初篩;局部最壞值指標（例如 SSIM 差異圖的最小值、誤差最大的前 1% 區域的平均誤差），因為 7.6.1 節的核心風險正是「平均很好但局部災難」;以及任務指標——由放射科醫師對同一批案例做盲測判讀，比較診斷結論的一致性。不能只用 PSNR 的理由見第 3.5 節與圖 3-16：抹掉一小塊的 PSNR 可能比整體加亮還好看。(b) 關鍵是要有「已知答案」的測試案例。做法是在乾淨影像上人工植入已知大小、已知對比度的微小病灶模擬物，再加入雜訊、跑完整條流程，檢查病灶是否仍可偵測、其對比度衰減了多少;並把病灶的尺寸與對比度逐步調小，找出「這套流程的偵測下限」。這個下限必須明確寫進規格與操作手冊。(c) 最大的風險通常不是演算法本身，而是信任的轉移：一旦醫師習慣了「處理後的影像看起來很乾淨」，就可能降低對原始影像的檢視，而演算法的失效模式恰好是「看起來很乾淨但東西不見了」——這種錯誤沒有警訊。對策是流程上強制保留並可隨時調閱原始影像，以及在處理後的影像上明確標註處理方式與版本。(d) 深度學習模型要額外驗收三件事：分布外表現（訓練資料沒見過的機型、序列、病灶型態）;幻覺風險——模型可能生成訓練資料中常見但本例不存在的結構（7.8.1 節的核心問題），這在醫學影像上是最危險的失效模式;以及可追溯性——模型版本、訓練資料來源、更新紀錄都必須納入醫材品質系統。一句話總結：傳統方法的錯誤通常「看得出來」（偽影、過度平滑），生成式方法的錯誤則「看不出來」，驗收的重點因此完全不同。

參考資料與延伸閱讀

- Gonzalez, R. C., & Woods, R. E., Digital Image Processing, 4th ed., Pearson, 2018, Ch. 5(影像還原與重建)。
- ESA/Hubble, History: The Spherical Aberration Problem.(本章叫獸開講之史料來源)

- Hanisch, R. J., & White, R. L., The Restoration of HST Images and Spectra II, STScI, 1994.
- Richardson, W. H., Bayesian-Based Iterative Method of Image Restoration, JOSA, 1972;Lucy, L. B., An Iterative Technique for the Rectification of Observed Distributions, AJ, 1974.
- Buades, A., Coll, B., & Morel, J.-M., A Non-Local Algorithm for Image Denoising, CVPR, 2005.(非局部平均原始論文)
- Hunt, B. R., The Application of Constrained Least Squares Estimation to Image Restoration by Digital Computer, IEEE Trans. Computers, 1973.
- Szeliski, R., Computer Vision: Algorithms and Applications, 2nd ed., Springer, 2022, Ch. 10(計算攝影與影像還原)。
- 補充教材與課程資訊：@prof(https://page.line.me/prof)